جامعة حلب

كلية الهندسة المعلوماتية

قسم الذكاء الصنعي واللغات الطبيعية

السنة الخامسة

التنبؤ بعمر الانسان باستخدام التعلم العميق

إعداد الطلاب:

عبد الرحمن شريقي

عبد الحسيب مصطفى

محمد أيهم عيان

محمود الخطيب

إشراف:

الدكتور محمد فاضل سكر

تاريخ 9\2025

يغطي هذا المشروع إحدى متطلبات نيل الإجازة في الهندسة المعلوماتية

Contents 1

2 مقدمة عامة :.....1

3 تاريخ تطور الذكاء الاصطناعي - من الفلسفة إلى الثورة التكنولوجية: 2

3.1 الذكاء الاصطناعي الحديث: النماذج اللغوية والتحولات الكبرى:.....4

محطات تاريخية لتعريفات مبكرة للذكاء الاصطناعي: 4

4 مفهوم التعلم العميق - The concept of Deep Learning : 5

5 الفرق بين التعلم العميق التقليدي وشبكات الطي العصبونية - Traditional Deep Learning V.S. CNN 5

أولًا: البنية المعمارية:.....5

ثانيًا: كثافة المعاملات(Parameters Density) 6

ثالثًا: استخراج الميزات(Feature Extraction) :.....6

رابعًا: التعميم(Generalization) 7

6 مجال الرؤية الحاسوبية: 7

7 طبيعة المشكلة: 7

8 تحديات تصنيف العمر - (Challenges in Age Classification):.....8

9 منهجية بناء النموذج - (Project Methodology Overview) :.....8

9.1 جمع بيانات كافية - (Dataset Collection):.....8

9.2 التحضير والمعالجة المسبقة للبيانات - (Data Preprocessing): 9

9.2.1 المعالجة المسبقة للبيانات الخاصة بالصور الرقمية: 9

9.3 اختيار المعمارية(Architecture Selection) : 13

9.4 مراحل التدريب:(Training Pipeline) 13

9.5 تقييم النموذج:(Evaluation Metrics) 13

9.6 متطلبات الأداء:(Performance Goals) 13

10 التدريب في CNN : 13

10.1 معمارية الشبكات العصبونية الالتفافية (CNN):..... 14
10.2 التعلم بالنقل – Transfer Learning : 15
10.3 فرط التكيف/التعلم - Overfitting : 15
11 الرؤية الحاسوبية..... 16
11.1 المهام الرئيسية للرؤية الحاسوبية 16
أنظمة الرؤية الحاسوبية: 17
11.2 أنواع الصور:..... 18
11.2.1 الصورة الرقمية: 18
11.2.2 الصورة الثنائية - Binary Image: 18
11.2.3 الصور الرمادية - Grayscale Image: 18
11.2.4 الصور الملونة - Colored Image: 19
11.3 نماذج الصور – Color Models:..... 19
11.3.1 نموذج RGB: 19
11.3.2 HSV Model 20
12 مفهوم عملية الطي الرياضي:..... 21
13 خريطة الميزات – Features Map:..... 24
14 شرح عن خصائص أو طبقات ال CNN:..... 25
14.1 بنية الشبكة:..... 25
14.2 طبقات الطي – Convolution Layers: 25
14.3 خطوة الانزلاق - Stride:..... 26
14.4 الحشو - Padding: 27
14.5 التجميع الأقصى – Max Pooling :..... 28
14.6 توليد مصفوفة أحادية – Flattening : 29
14.7 طبقة كاملة الاتصال – Fully-Connected layer : 29

15 نظرة عامة حول الشبكات التوليدية الخصمية(GANs) 29
مقدمة:(Introduction) 29
15.1 مميزات وعيوب الشبكات التوليدية الخصمية:(Pros & Cons) 30
المميزات: 30
لماذا يُوصى باستخدام GANs على شبكات أخرى؟ 31
15.2 البنية العامة للشبكات التوليدية الخصمية:(General Structure) 31
15.3 GANs Flow Chart 32
تطبيقات عملية متقدمة لـ:GANs 33
16 توابع التفعيل - Non-linearity functions: 33
16.1 أشهر توابع التفعيل: 34
17 خوارزمية التحسين "آدم(Adam Optimizer) " 37
17.1 المبدأ الرياضي وآلية العمل 37
الخصائص والمزايا 38
التطبيقات العملية 39
التحديات والقيود 39
18 لغة Python: 39
19 بعض المكاتب الشهيرة 40
20 إطار العمل – TensorFlow 43
21 قاعدة البيانات 44
معنى قاعدة البيانات 44
21.1 أنواع مجموعات البيانات 44
21.2 مجموعات البيانات المستخدمة – UTKFace DataSet: 44
22 التطبيق العملي: 46
22.1 النسخة الأولى – Version 1 : 47

22.1.1 خرج الشبكة الالتفافية بالنسخة الأولى – CNN OUTPUT for each Epoch .. 48
22.1.2 خرج الشبكة التنافسية بالنسخة الأولى – GAN OUTPUT For Each Epoch..... 48
22.1.3 نتائج النسخة الأولى..... 49
22.2 النسخة الثانية:..... 52
22.2.1 خرج الشبكة التنافسية بالنسخة الثانية – GAN OUTPUT For Each Epoch..... 52
22.2.2 خرج الشبكة الالتفافية بالنسخة الثانية – CNN OUTPUT for each Epoch 52
22.3 النسخة الثالثة للتدريب – V3 : 55
22.3.1 خرج الشبكة التنافسية بالنسخة الثالثة – GAN OUTPUT For Each Epoch..... 55
22.3.2 خرج الشبكة الالتفافية بالنسخة الثالثة – CNN OUTPUT for each Epoch 56
22.4 النسخة النهائية للتدريب – Final Version:..... 58
22.4.1 خرج الشبكة التنافسية بالنسخة الأولى – GAN OUTPUT For Each Epoch..... 58
22.4.2 خرج الشبكة الالتفافية بالنسخة الأولى – CNN OUTPUT for each Epoch .. 59
22.4.3 ملخّص التدريب والتقييم..... 62
22.4.4 خلاصة ومقارنة للنتائج بالنسخ السابقة 64
23 الخلاصة**:**..... 66
24 الخاتمة..... 66
25 آفاق البحث والتطوير:(Future Work and Improvements) 66

2 مقدمة عامة :

الذكاء الاصطناعي (Artificial Intelligence - AI) يُعدّ من أعظم الإنجازات العلمية والتكنولوجية في العصر الحديث، إذ يمثل ثورة معرفية غير مسبوقة تعيد تشكيل مختلف مناحي الحياة البشرية.

يرتكز مفهوم الذكاء الاصطناعي على تطوير الأنظمة الحاسوبية القادرة على محاكاة القدرات الإدراكية والمعرفية للبشر، مثل الفهم، التحليل، التعلم، اتخاذ القرار، بل والتكيف الذاتي مع المعطيات المتغيرة في البيئة المحيطة.

إن الأهمية المتعاظمة للذكاء الاصطناعي لا تنبع فقط من قدرته على أتمتة العمليات التقليدية وزيادة الكفاءة الإنتاجية، بل تتعدى ذلك إلى كونه أداة حيوية في توليد المعرفة، استشراف المستقبل، ودفع حدود الابتكار العلمي والتقني.

لقد أصبح الذكاء الاصطناعي عنصراً محورياً في العديد من القطاعات الحيوية، من الرعاية الصحية حيث تُستخدم خوارزميات التعلم العميق (Deep Learning) في تشخيص الأمراض بدقة تفوق أحياناً الخبراء البشريين، إلى الصناعات التحويلية التي تعتمد على أنظمة الذكاء الصناعي لتحسين سلاسل الإمداد، وتوقّع الأعطال الفنية قبل حدوثها.

كما يشكل الذكاء الاصطناعي العمود الفقري لتقنيات السيارات ذاتية القيادة، والمساعدات الرقمية الذكية، وتحليلات البيانات الضخمة(Big Data Analytics) ، فضلاً عن دوره المتعاظم في مجالات الأمن السيبراني، والتمويل، والتعليم الذكي.

تاريخياً، تعود جذور الذكاء الاصطناعي إلى منتصف القرن العشرين، حين طرح العلماء الأوائل مثل آلان تورنغ (Alan Turing) فكرة إمكانية محاكاة "التفكير البشري" بواسطة الآلات. وقد شكّل "اختبار تورنغ" أول إطار نظري لتقييم قدرة الحواسيب على إظهار سلوك ذكي. إلا أن الانطلاقة الحقيقية للذكاء الاصطناعي جاءت مع تطور الحوسبة وظهور خوارزميات الشبكات العصبية الاصطناعية (Artificial Neural Networks)التي استُلهم تصميمها من طريقة عمل الخلايا العصبية في الدماغ البشري. ومع التقدم الهائل في قدرة المعالجة الحاسوبية، وتوفر كميات ضخمة من البيانات (Big Data)، برزت تقنيات التعلم الآلي (Machine Learning) والتعلم العميق (Deep Learning) كأدوات رئيسية في دفع الذكاء الاصطناعي إلى آفاق غير مسبوقة.

في العقد الأخير، شهد العالم طفرة نوعية في تقنيات الذكاء الاصطناعي مع تطور نماذج اللغة الضخمة (Large Language Models)وأنظمة التعلم التعزيزي(Reinforcement Learning) ، حيث أصبحت هذه الأنظمة قادرة على أداء مهام تتطلب مستوى عالٍ من "الحدس" و"الفهم السياقي"، وهو ما كان يُعدّ حكراً على العقل البشري.

هذا التقدم لم يكن ليتحقق إلا بفضل الأبحاث المستمرة في مجالات الحوسبة السحابية (Cloud Computing)، والهندسة الخوارزمية المتقدمة، والتقنيات الموازية مثل الحوسبة الكمومية (Quantum Computing)التي تبشر بقفزة نوعية في إمكانيات الذكاء الاصطناعي في المستقبل القريب.

ختاماً، لا يمكن إنكار أن الذكاء الاصطناعي أصبح بمثابة "القوة الدافعة" للعصر الرقمي الجديد، حيث يعاد رسم حدود الممكن في كافة المجالات. ومع ذلك، تبرز الحاجة الماسة إلى أطر أخلاقية وقانونية تنظم استخدام هذه التكنولوجيا لضمان أن يبقى الذكاء الاصطناعي أداة لخدمة الإنسانية، لا تهديداً لها. فالمستقبل يحمل وعوداً هائلة بقدر ما يحمل من تحديات، والذكاء الاصطناعي يقف في قلب هذا المستقبل كعنصر محوري في صياغة ملامحه.

3 تاريخ تطور الذكاء الاصطناعي - من الفلسفة إلى الثورة التكنولوجية:

- **النشأة الفكرية للذكاء الاصطناعي:**
على الرغم من أن مصطلح "الذكاء الاصطناعي (Artificial Intelligence) "لم يظهر كمصطلح علمي متداول إلا في منتصف القرن العشرين، إلا أن جذوره الفكرية والفلسفية تعود إلى قرون عديدة قبل ذلك. فقد شغلت فكرة "صناعة آلة قادرة على التفكير" عقول الفلاسفة والعلماء منذ عهد الفلاسفة الإغريق، الذين ناقشوا لأول مرة مفهوم "المنطق الصوري (Formal Logic) "كأداة لتفسير الفكر البشري.

- **في القرن السابع عشر**:
طرح الفيلسوف والعالم الرياضي **غوتفريد لايبنتز** (**Gottfried Wilhelm Leibniz**) فكرة إمكانية تطوير "آلة منطقية" تستطيع معالجة الرموز وإجراء العمليات الفكرية بطريقة ميكانيكية. هذه الفكرة، رغم طابعها الفلسفي حينها، كانت نواة للمفاهيم التي ستتبلور لاحقاً في قلب الذكاء الاصطناعي.

- **بدايات القرن العشرين:**
منطق الرياضيات والحوسبة النظرية مع بدايات القرن العشرين، بدأ الفكر العلمي في تقنين عملية التفكير البشري ضمن أطر رياضية صارمة، خصوصاً مع ظهور أعمال
كورت غودل **Kurt Gödel** في المنطق الرياضي، ثم جاء المفكر البريطاني آلان تورنغ **Alan Turing**، الذي يمكن اعتباره "الأب الروحي للحوسبة" بطرحه في عام 1936 لما عُرف لاحقاً بـ "آلة تورنغ — (Turing Machine) "وهو نموذج نظري لحاسوب قادر على تنفيذ أي خوارزمية يمكن توصيفها رياضياً.

- **وفي عام 1950** نشر تورنغ بحثه الشهير:
"آلات الحوسبة والذكاء(Computing Machinery and Intelligence) ، حيث قدم اختباراً

عملياً سُمّي لاحقاً بـ "اختبار تورنغ (Turing Test) "لقياس قدرة الحواسيب على إظهار سلوكيات تُعدّ ذكية من منظور بشري. كان هذا البحث بمثابة أول خطوة جادة نحو جعل الذكاء الاصطناعي مجالاً علمياً قابلاً للقياس والتطبيق.

- **صيف دارتموث 1956:**
ولادة المصطلح وتعريف جون مكارثي رغم الجهود السابقة، إلا أن الولادة الرسمية لمجال الذكاء الاصطناعي كمجال علمي مستقل جاءت في صيف عام 1956، في الورشة العلمية الشهيرة التي انعقدت في كلية دارتموث (Dartmouth College) بولاية نيوهامبشير الأمريكية، والتي دعا إليها عالم الحوسبة الأمريكي جون مكارثي(John McCarthy) ، إلى جانب كل من مارفن مينسكي (Marvin Minsky)، كلود شانون(Claude Shannon) ، وناثانيال روشستر (Nathaniel Rochester) .

- **في الدعوة الرسمية لهذه الورشة،** قدّم مكارثي أول تعريف رسمي لمفهوم الذكاء الاصطناعي قائلاً:
"نقترح أن تتم دراسة إمكانية جعل الآلات تتعلم، وتستخدم اللغة، وتشكل مفاهيم وتحل المشكلات التي تُعدّ حتى الآن مقصورة على البشر. سنحاول اكتشاف كيف يمكن جعل الآلات تتصرف كما لو كانت ذكية".
هذا التعريف لم يكن مجرد توصيف لغوي، بل كان إعلاناً عن ميلاد مجال علمي جديد، سيصبح في العقود التالية من أعظم مجالات البحث في تاريخ البشرية.

- **الستينيات والسبعينيات:** الطموح المفرط والخيبة الواقعية
في الستينيات، ومع تطور أجهزة الحاسوب البدائية، كان هناك تفاؤل مفرط في الأوساط العلمية بإمكانية بناء آلات ذكية بالكامل خلال سنوات قليلة. ظهرت آنذاك برامج مثل ELIZA (1966)التي كانت تحاكي محادثات البشر بشكل بدائي، وكذلك أنظمة الخبراء (Expert Systems) مثل DENDRAL و MYCINالتي استخدمت قواعد معرفية لحل مشكلات متخصصة في مجالات مثل التشخيص الطبي. إلا أن محدودية قدرة الحوسبة، ونقص البيانات، وسوء تقدير تعقيد الإدراك البشري، أدت إلى دخول الذكاء الاصطناعي فيما عُرف لاحقاً بـ "شتاء الذكاء الاصطناعي — (AI Winter) "وهي فترات من الركود العلمي والتمويلي أصابت المجال في السبعينيات والثمانينيات.

- **من الشبكات العصبية إلى التعلم العميق**
في نهاية الثمانينيات وبداية التسعينيات، بدأت موجة جديدة من الأبحاث، لا سيما مع تطوير الشبكات العصبية الاصطناعية (Artificial Neural Networks) التي استلهمت بنيتها من طريقة عمل الدماغ البشري. قدم العلماء مثل جيفري هينتون (Geoffrey Hinton) تقنيات جديدة لتدريب هذه الشبكات، ومع تطور قدرات الحوسبة ومعالجات الرسوميات(GPUs) ، شهدت الشبكات العصبية قفزات هائلة.
ظهر مفهوم "**التعلم العميق (Deep Learning) "**كإطار خوارزمي لبناء شبكات ذات طبقات متعددة قادرة على التعلم التدرجي للأنماط، مما أعاد الأمل في بناء أنظمة ذكاء اصطناعي حقيقية.

وقد كان الإنجاز الأبرز في هذا السياق انتصار نموذج AlexNet في مسابقة ImageNet 2012، حيث أظهر قدرات تصنيفية تفوقت بشكل ملحوظ على النماذج التقليدية.

3.1 الذكاء الاصطناعي الحديث: النماذج اللغوية والتحولات الكبرى:

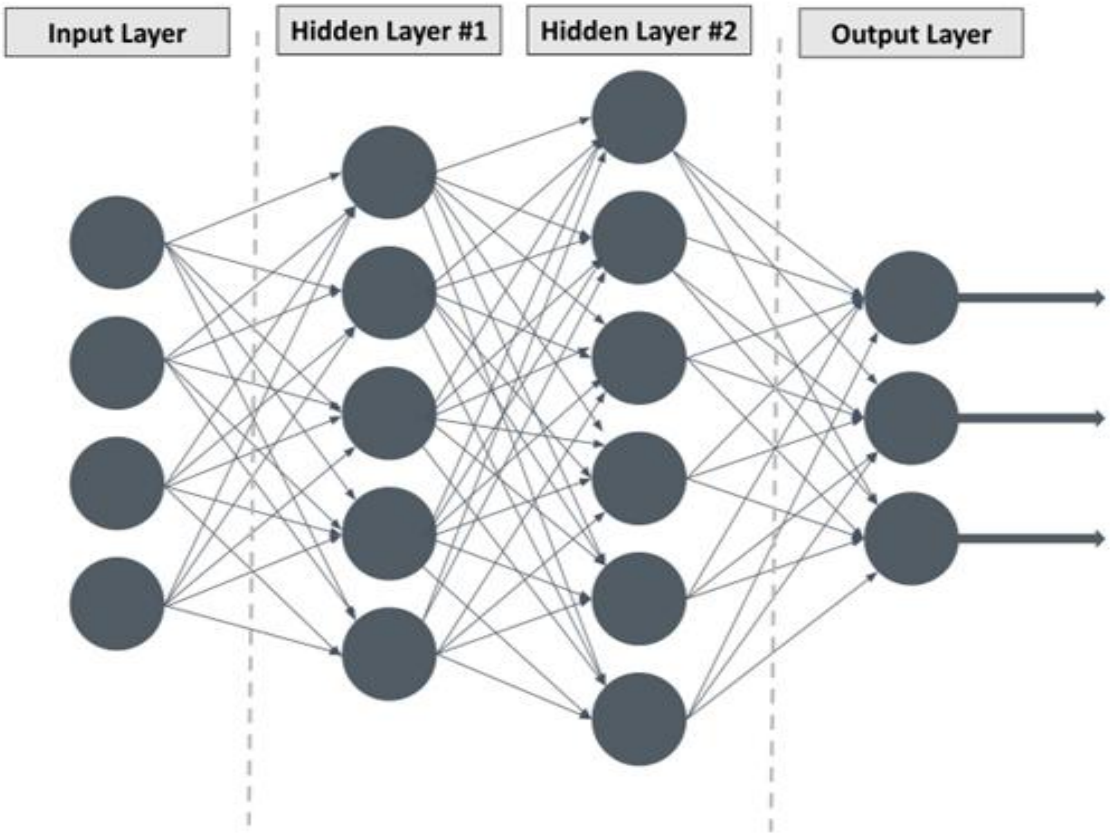
- في العقد الأخير، شهد العالم تطورات ثورية مع ظهور النماذج اللغوية الضخمة مثل:
  - Large Language Models - LLMs
  - GPT (Generative Pre-trained Transformer
    والتي أعادت تعريف إمكانيات الذكاء الاصطناعي في مجالات فهم اللغة الطبيعية (Natural Language Understanding)
  - وتوليد النصوص(Text Generation)
- التقدم في تقنيات مثل التعلم التعزيزي(Reinforcement Learning) ، والحوسبة السحابية (Cloud Computing)، والبيانات الضخمة(Big Data) ، إضافة إلى الأبحاث المتقدمة في الذكاء الاصطناعي التوليدي(Generative AI) ، الذكاء الاصطناعي اليوم ليس مجرد حلم علمي، بل منظومة معرفية تعيد صياغة شكل الاقتصاد، والتعليم، والرعاية الصحية، والفن، بل وحتى الفلسفة.

محطات تاريخية لتعريفات مبكرة للذكاء الاصطناعي:

التعريف	الشخصية	التاريخ
"إذا لم يستطع المراقب تمييز إذا ما كان يتحدث إلى إنسان أو آلة، فإن الآلة يمكن اعتبارها ذكية." (اختبار تورنغ)	آلان تورنغ	1950
"علم وهندسة صناعة الآلات الذكية".	جون مكارثي	1956
"ذكاء اصطناعي هو أي عملية تقوم بها آلة إذا ما قام بها إنسان لتطلبنا أن نقول عنه أنه ذكي".	مارفن مينسكي	1958
"الذكاء الاصطناعي هو تصميم برامج حاسوبية قادرة على أداء مهام تتطلب ذكاءً بشرياً".	نيلسون مينسكي وبيتر نورفيغ	1980s

4 مفهوم التعلم العميق - The concept of Deep Learning :

- التعلم العميق هو فرع من تعلم الآلة يتضمن تدريب الشبكات العصبونية الاصطناعية بعدة طبقات لتعلم تمثيلات معقدة للبيانات. طبعا تعد (CNN) هي نوع من نماذج التعلم العميق.



الشكل: 3 - 1
بنية شبكة عصبية متعددة الطبقات تتضمن طبقة إدخال، طبقتين مخفيتين، وطبقة إخراج

5 الفرق بين التعلم العميق التقليدي وشبكات الطي العصبونية - Traditional Deep Learning V.S. CNN

أولًا: البنية المعمارية:

- **التعلم العميق(Deep Learning) :**

التعلم العميق هو إطار عام يضم مجموعة من النماذج العصبية متعددة الطبقات، مثل الشبكات الكثيفة (Dense Networks)، الشبكات التكرارية(RNN) ، والشبكات الالتفافية .(CNN) يتميز هذا النهج بوجود طبقات متتالية من المعالجة، حيث تتعلم كل طبقة تمثيلًا أكثر تجريدًا من الطبقة السابقة. البنية قد تكون خطية أو متفرعة، وتُستخدم في معالجة أنواع مختلفة من البيانات مثل الصور، النصوص، والصوت.

- **الشبكات الالتفافية(CNN)**

شبكات CNN هي نوع متخصص ضمن التعلم العميق، صُممت لمعالجة البيانات الصورية تحديدًا. تتكون من طبقات الالتفاف (Convolutional Layers) التي تُطبّق فلاتر صغيرة على الصورة لاستخراج الأنماط المحلية، يليها طبقات التجميع (Pooling) لتقليل الأبعاد، ثم طبقات كثيفة للربط النهائي. هذه البنية تُحاكي الطريقة التي يُحلل بها الدماغ البشري الصور، وتُعد أكثر كفاءة في التعامل مع البنية المكانية للبيانات.

ثانيًا: كثافة المعاملات(Parameters Density)

- **التعلم العميق**

في النماذج الكثيفة مثل الشبكات متعددة الطبقات(MLP) ، تحتوي كل طبقة على عدد كبير من المعاملات، حيث يُربط كل مدخل بكل مخرج. هذا يؤدي إلى كثافة عالية في المعاملات، مما يزيد من الحاجة إلى موارد حسابية ضخمة، ويُعرض النموذج لخطر فرط التكيف (Overfitting) خاصة عند التعامل مع بيانات محدودة.

- **الشبكات الالتفافية(CNN)**

تتميز CNN بكثافة منخفضة نسبيًا في المعاملات، بفضل استخدام الفلاتر المشتركة عبر الصورة. كل فلتر يُطبق على كامل الصورة بطريقة انزلاقية، مما يُقلل عدد المعاملات بشكل كبير. هذا يُساهم في تحسين الكفاءة الحسابية، ويُقلل من خطر فرط التكيف، خاصة في المهام التي تتطلب معالجة صور عالية الدقة .

ثالثًا: استخراج الميزات(Feature Extraction) :

- **التعلم العميق**

يعتمد التعلم العميق على التعلم التمثيلي، حيث تُستخرج الميزات تلقائيًا من البيانات الخام عبر طبقات متعددة. تختلف طريقة الاستخراج حسب نوع النموذج؛ فمثلًا، الشبكات التكرارية تُجيد التعامل مع التسلسلات الزمنية، بينما الشبكات الكثيفة تُعالج البيانات المجدولة.

- **الشبكات الالتفافية(CNN)**

تُعد CNN من أفضل النماذج لاستخراج الميزات البصرية، حيث تقوم طبقات الالتفاف بالتقاط الأنماط المكانية مثل الحواف، الزوايا، والأنسجة. يتم ذلك بطريقة هرمية، حيث تُستخرج الميزات البسيطة في

الطبقات الأولى، ثم تُدمج لتكوين ميزات أكثر تعقيدًا في الطبقات اللاحقة. هذه القدرة تجعل CNN مثالية لمهام مثل تصنيف الصور، اكتشاف الكائنات، وتقدير العمر.

رابعًا: التعميم(Generalization)

- **التعلم العميق**

تعتمد قدرة النموذج على التعميم على عدة عوامل، منها حجم البيانات، بنية النموذج، وتقنيات التنظيم مثل Dropout و .Regularizationالنماذج ذات المعاملات الكثيفة قد تُظهر أداءً ممتازًا على بيانات التدريب، لكنها تُعاني من ضعف التعميم على بيانات جديدة إذا لم تُضبط بشكل جيد.

- **الشبكات الالتفافية(CNN)**

تُظهر CNN قدرة جيدة على التعميم، خاصة في المهام الصورية، بفضل بنيتها التي تُقلل عدد المعاملات وتُحافظ على البنية المكانية للبيانات. استخدام تقنيات مثل التجميع(Pooling) ، التطبيع (Batch Normalization)، والانحدار المنتظم يُعزز من قدرة النموذج على التعميم، ويُقلل من خطر فرط التكيف.

---

6 مجال الرؤية الحاسوبية:

- في عصر الذكاء الاصطناعي، أصبح تحليل الصور الرقمية وفهم محتواها من المهام الأساسية في مجالات متعددة مثل الأمن، التسويق، الرعاية الصحية، وتطبيقات الهواتف الذكية.
ومن بين أكثر المهام تحدياً وإثارة في مجال **الرؤية الحاسوبية (Computer Vision)** نجد مهمة **تصنيف العمر (Age Classification)**من الصورالرقمية.
- تتمثل هذه المهمة في تطوير نموذج حاسوبي ذكي يستطيع تلقائياً، عند تزويده بصورة وجه إنسان، تحديد جنس الشخص (ذكر أو أنثى)، بالإضافة إلى تقدير عمره إما كقيمة عددية تقريبية أو ضمن فئة عمرية معينة. هذا النوع من المشكلات ينتمي إلى تقاطع بين **تصنيف الصور (Image Classification)**و**تقدير السمات(Attribute Estimation) .**

7 طبيعة المشكلة:

- تقدير العمر:(Age Estimation)

يمكن التعامل معها بطرق متعددة:

تصنيف الفئات العمرية :(Age Group Classification) حيث يتم تقسيم العمر إلى مجموعات (مثل 0-10، 11-20، إلخ).

التقدير العددي :(Age Regression) حيث يُطلب من النظام إعطاء قيمة رقمية دقيقة للعمر.

تصنيف العمر بالتدرج :(Ordinal Regression) حيث يتم التعامل مع العمر كقيمة مرتبة.

- الخصائص المشتركة بين الجنس والعمر(Joint Learning) :

العمر والجنس هما سمات مستقلة لكنها مترابطة في السياق البصري؛ لذا يمكن تطوير نموذج متعدد المخرجات (Multi-output Model) لتعلم المهمتين معًا.

8 تحديات تصنيف العمر - (Challenges in Age Classification):

- تنوع ملامح – (Intra-class Variability):

الاختلافات الطبيعية بين الأفراد ضمن نفس الفئة العمرية (بسبب الجينات، نمط الحياة، العوامل البيئية).

- التشابه بين الفئات - Inter-class Similarity:

أحياناً تكون ملامح الأشخاص من فئات عمرية مختلفة متشابهة للغاية، خاصة في الأعمار المتقاربة (مثلاً شخص بعمر 25 وآخر بعمر 30).

- ظروف التصوير-Image Acquisition Conditions :

اختلاف زوايا الوجه، الإضاءة غير المتجانسة، جودة الكاميرا، أو وجود عوائق جزئية (مثل نظارات الشمس أو الأقنعة) يؤثر سلباً على الدقة.

- التحيّز في البيانات – Data Bias:

العديد من مجموعات البيانات المتوفرة تحتوي على تمثيل غير متوازن لبعض الفئات (مثلاً تمثيل زائد للأشخاص البالغين وقليل للأطفال أو المسنين).

- التغيرات الزمنية - Temporal Variability:

مع مرور الزمن تتغير ملامح الأشخاص بشكل تدريجي، مما يجعل تقدير العمر مهمة ديناميكية تتطلب فهمًا معمقاً للسمات الطفيفة.

9 منهجية بناء النموذج - (Project Methodology Overview) :

9.1 جمع بيانات كافية - (Dataset Collection):

يجب جمع مجموعة بيانات غنية ومتنوعة تحتوي على صور وجوه بمختلف الأعمار والأجناس والثقافات.

الاهتمام بجمع بيانات تمثل:

- تنوع الأعراق (Ethnicity Diversity)
- تفاوت الأعمار بدقة (Age Granularity)
- اختلافات بيئية (Lighting, Backgrounds)

9.2 التحضير والمعالجة المسبقة للبيانات - (Data Preprocessing):

- تُعد المعالجة المسبقة للبيانات مرحلة جوهرية في أي نظام يعتمد على البيانات، سواء في **التعلم الآلي** أو **التنقيب في البيانات** أو **معالجة الصور والنصوص**. وتشير هذه العملية إلى مجموعة من الخطوات المنهجية التي تهدف إلى **تحضير البيانات الخام** وجعلها في صورة مناسبة لمعالجة لاحقة أكثر كفاءة ودقة.
- غالبًا ما تكون البيانات الأولية غير جاهزة مباشرة للاستخدام، إذ قد تحتوي على **قيم ناقصة، ضوضاء، تكرار، اختلاف في الأبعاد، أو مجالات غير متجانسة**. ومن هنا تأتي أهمية المعالجة المسبقة التي تُعتبر بمثابة "مرحلة تنظيف وتجهيز" تؤثر بشكل مباشر على جودة النتائج النهائية لأي نموذج أو تحليل.

- الأهمية العلمية للمعالجة المسبقة

- **تحسين جودة البيانات :**إزالة الأخطاء والضوضاء والتناقضات مما يجعل البيانات أكثر موثوقية.
- **زيادة دقة النماذج :**النماذج الإحصائية وخوارزميات التعلم الآلي تعمل بكفاءة أعلى عند التعامل مع بيانات منظمة وموحدة.
- **تقليل التكلفة الحسابية :**من خلال تقليص حجم البيانات أو إعادة تمثيلها بشكل مضغوط، مما يسرّع من عمليات التدريب أو التحليل.
- **التوافق بين المصادر المختلفة :**عندما تأتي البيانات من أنظمة أو أجهزة متعددة، تساعد المعالجة المسبقة على توحيد الصيغ والقيم.

- المراحل الشائعة في المعالجة المسبقة

- **تنظيف البيانات :(Data Cleaning)** معالجة القيم المفقودة والتكرار والضوضاء.
- **التحويل :(Data Transformation)** مثل إعادة القياس (Rescaling) أو الترميز.(Encoding)
- **التقليل :(Data Reduction)** تقليص الأبعاد أو ضغط البيانات دون فقدان للمعلومات المهمة.
- **التكامل :(Data Integration)** دمج البيانات القادمة من مصادر مختلفة في شكل موحّد.

9.2.1 المعالجة المسبقة للبيانات الخاصة بالصور الرقمية:

- توحيد الأبعاد - Image Resizing

توحيد الأبعاد هو إحدى الخطوات الأساسية في معالجة الصور الرقمية، ويقصد به تعديل أبعاد الصورة (عدد الصفوف والأعمدة المكوّنة لمصفوفة البكسلات) بحيث تصبح جميع الصور في مجموعة البيانات ذات حجم موحّد. هذه العملية تكتسب أهمية خاصة عند استخدام الصور في التطبيقات الخوارزمية أو النماذج الذكية، إذ تتطلب معظم الخوارزميات أن تكون الصور الداخلة متساوية في الطول والعرض لسهولة المعالجة والمقارنة.

- **الأهمية العلمية لتوحيد الأبعاد - Image Resizing :**

التوافق الحسابي :

العديد من خوارزميات الرؤية الحاسوبية مثل الشبكات العصبية الالتفافية CNNs لا تستطيع التعامل مع صور مختلفة الأبعاد.

تسريع العمليات الحسابية :توحيد الأبعاد يقلل من تباين حجم المدخلات وبالتالي يساهم في تحسين الأداء وسرعة التدريب أو التحليل.
إزالة التحيّز الناتج عن الحجم :إذا اختلفت أبعاد الصور بشكل كبير، فإن ذلك قد يؤثر على دقة التصنيف أو جودة استخراج المميزات.

- **الأساليب الشائعة لتغيير الحجم**

- **الاستيفاء الخطي :(Bilinear Interpolation)** يعتمد على المتوسط الخطي لقيم البكسلات المجاورة، ويُعدّ مناسبًا للتقليل من التشوهات.

- **الاستيفاء التكعيبي :(Bicubic Interpolation)** يستخدم 16 بكسلًا مجاورًا لحساب القيمة الجديدة، مما يعطي نتائج أكثر سلاسة ودقة.

- **التحجيم الأقرب :(Nearest Neighbor)** أبسط الطرق حيث يتم اختيار أقرب بكسل من الصورة الأصلية، وهو أسرع لكنه قد يؤدي إلى مظهر متدرج(pixelated)

- **المنهجية والتطبيقات العملية:**

عند تقليص حجم الصورة بشكل كبير قد تضيع تفاصيل مهمة، مما يؤثر على جودة التحليل.
عند تكبير الصورة قد تظهر ضوضاء أو ضبابية (Blur) يُفضّل اختيار حجم قياسي يتناسب مع طبيعة البيانات وتوازن بين الدقة والكلفة الحسابية.

- **التعرف على الوجوه** :عادة تُحوَّل جميع صور الوجوه إلى حجم ثابت مثلاً 224×224 بكسل.
- في **المسح الطبي** :تُوحّد أبعاد صور الأشعة قبل إدخالها إلى أنظمة التشخيص بمساعدة الحاسوب.
- في **التعلّم العميق** :تُستخدم أحجام قياسية مثل 256×256 أو 512×512 لتدريب الشبكات العصبية.

- **توحيد مجال قيم البكسلات Pixels Standardization**

المعايرة العددية للبكسلات هو عملية إعادة معايرة القيم الرقمية للبكسلات ضمن نطاق محدد، بغرض توحيد تمثيل الصور وتحسين أداء الخوارزميات.
في الصور الرقمية تكون قيم البكسلات عادة في مجال [0 – 255] (8-bit) إلا أنّ هذا المجال قد لا يكون مناسبًا للتعلّم الآلي أو الخوارزميات الإحصائية، إذ يمكن أن يؤدي اختلاف نطاق القيم إلى بطء في تقارب النماذج أو إلى تحيزات غير مرغوبة.

الأهمية العلمية:

- **تسريع التدريب** :عند تقليل مدى القيم (مثلاً إلى 0–1) يصبح حساب الانحدار gradient أكثر استقرارًا، ما يُسرّع من عملية التدريب.

- **تحسين الدقة العددية :**إن توحيد المجال يقلل من مشاكل التفاوت الكبير في القيم، مما يحسن دقة العمليات الحسابية.

- **زيادة قابلية المقارنة :**الصور من مصادر مختلفة قد تُخزن بقيم متفاوتة، و Pixel Standardization يجعلها قابلة للمقارنة المباشرة.

الأساليب الشائعة لتوحيد مجال البكسلات:

1. **توحيد المجالات إلى المجال [0,1]**

2. **توحيد المجالات إلى المجال [-1,1]**

3. **التوحيد الإحصائي:(Z-score Standardization)**

$$z = \frac{x - \mu}{\sigma}$$

$$\mu = \text{Mean}$$
$$\sigma = \text{Standard Deviation}$$

- حيث **μ** هو المتوسط و **σ** هو الانحراف المعياري للقيم.
يهدف هذا الأسلوب إلى جعل التوزيع بمتوسط صفر وانحراف معياري واحد.

الاعتبارات المنهجية القياسية:

- يجب تحديد طريقة إعادة القياس بما يتوافق مع نوع الخوارزمية المستخدمة.

- عند استخدام التوحيد الإحصائي، يُفضل حساب **μ** و **σ** على كامل مجموعة التدريب للحفاظ على التناسق.

- من الضروري تطبيق نفس أسلوب إعادة القياس على جميع مراحل البيانات (تدريب، تحقق، اختبار).

متطلبات بعض التطبيقات العملية:

- التعلم العميق :غالبية النماذج العصبية تتطلب إعادة القياس إلى [0,1] أو.[-1,1]
- التصوير الطبي :إزالة الفروقات الناتجة عن اختلاف أجهزة التصوير.
- التعرف على الأنماط :معالجة الصور الملتقطة في ظروف إضاءة متفاوتة لتسهيل المقارنة.

- زيادة البيانات اصطناعياً(Data Augmentation) :

زيادة البيانات أو Data Augmentationهي تقنية تُستخدم في مجال الذكاء الاصطناعي وتعلّم الآلة، خاصة في تعلم الآلة العميق(Deep Learning) ، بهدف توليد بيانات جديدة من البيانات الموجودة دون الحاجة لجمع بيانات إضافية من الواقع.
الفكرة هي أخذ البيانات الأصلية (صور، نصوص، صوت...) وإجراء تعديلات عليها بحيث تبقى المعنى أو الفئة نفسها، لكن تصبح لدينا عينات أكثر للتدريب.

لماذا نستخدمها؟

حل مشكلة قلة البيانات :عندما يكون لدينا عدد قليل من العينات، قد يتعلم النموذج بشكل ضعيف أو يتعرض لمشكلة (Overfittingحفظ البيانات بدل فهم الأنماط.)
تحسين دقة النموذج :البيانات المتنوعة تساعد النموذج على التعميم بشكل أفضل.
توفير الوقت والمال :بدلاً من جمع بيانات جديدة، نولّدها من الموجودة.

أمثلة على أساليبData Augmentation

- في الصور :

- **التدوير(Rotation)**
- **القص(Cropping)**
- **قلب الصورة أفقيًا أو عموديًا(Flipping)**
- **تغيير الإضاءة أو الألوان**
- **إضافة ضوضاء(Noise)**

- في النصوص :

- **استبدال كلمات بمرادفاتها**
- **تغيير ترتيب الكلمات مع الحفاظ على المعنى**
- **حذف أو إضافة كلمات بسيطة**
- **الترجمة إلى لغة أخرى ثم العودة للغة الأصلية (Back Translation)**

- في الصوت :

- **تغيير سرعة الصوت.**
- **تغيير النغمة(Pitch) .**
- **إضافة ضوضاء خلفية.**

مثال عن توليد البيانات صناعيا (صور) :

لو كان لدينا 100 صورة لقطط، يمكننا عبر التدوير، القص، وتغيير الإضاءة توليد 500 صورة جديدة، مما يجعل النموذج يرى القطط في أوضاع وإضاءات مختلفة، فيتعلّم بشكل أفضل.

في حالة وجود بيانات نصية للعمر(Strings) ، يجب تحويلها إلى قيم عددية باستخدام **Label Encoding or One-Hot Encoding**

9.3 اختيار المعمارية(Architecture Selection) :

- البدء بنماذج بسيطة مثل **Convolutional Neural Networks (CNNs)**.
- الاستفادة من **Transfer Learning**باستخدام نماذج مدربة مسبقاً على مجموعات بيانات ضخمة مثل MobileNetV2، Efficient Net
- بناء نموذج مخصص بمخرجين :(Output Heads) مخرج لتصنيف الجنس، وآخر لتقدير العمر.

9.4 مراحل التدريب:(Training Pipeline)

تقسيم البيانات إلى تدريب/تحقق/اختبار.
استخدام خوارزميات تحسين فعالة.
مراقبة الأداء باستخدام أدوات مثل.

9.5 تقييم النموذج:(Evaluation Metrics)

قياس **خطأ التقدير (MAE, MSE)** في تقدير العمر.
تحليل **مصفوفة الالتباس (Confusion Matrix)** لمعرفة الفئات التي يحدث بها خلط.

9.6 متطلبات الأداء:(Performance Goals)

الوصول إلى دقة تصنيف للجنس تتجاوز **90%**.
تحقيق متوسط خطأ في تقدير العمر (MAE) يقل عن **5سنوات**.
ضمان قدرة النموذج على التعميم (Generalization) وعدم الاعتماد المفرط على سمات ظاهرية سطحية.

10 التدريب في CNN :

تشبه عملية التدريب على CNN تلك الخاصة بالشبكات العصبية للتغذية الأمامية. وبالمثل، يتم تعلم معاملات الشبكة عن طريق خوارزمية الانتشار الخلفي وتحسين الانحدار الاشتقاقي .
المرحلة الأولى هي الانتشار الأمامي، حيث تنتشر الإشارات من مدخلات الشبكة إلى الخرج.
في الطبقة الأخيرة، تتم مقارنة الخرج بواسطة دالة التكلفة بالقيمة المطلوبة ويتم تقدير الخطأ في المرحلة الثانية، يتم استخدام خوارزمية الانتشار الخلفي مرة أخرى لتعويض هذا الخطأ، ومع ذلك، فإن عملية التعلم في الشبكة العصبية الالتفافية أكثر تعقيدا مما هي عليه في الشبكة العصبية للتغذية الأمامية، حيث تتكون من أنواع مختلفة من الطبقات، وتتبع مرحلنا الانتشار الأمامي والخلفي قواعد محددة في كل طبقة.
الخلايا العصبية في الشبكة العصبية الالتفافية لها وزن مشترك، على عكس الشبكة العصبية أمامية

التغذية، حيث يكون لكل خلية عصبية متجه وزن منفصل يؤدي تقاسم الأوزان هذا إلى تقليل إجمالي عدد الأوزان القابلة للتدريب.

أسباب استخدام CNNs لتصنيف الصور:

هناك عدة أسباب لاستخدام شبكات CNNs عادةً ما تؤدي الصورة كمدخلات إلى طبقات كبيرة جدًا، في حال تم استخدام شبكة عصبية عادية فقط، فإن الاتصال الكامل بين الطبقات يتطلب قدرًا كبيرًا من الذاكرة لتخزين الأوزان في طبقة الالتفاف الى يوجد اتصال كامل على النقيض من ذلك هناك اتصال مبعثر. ينتج عن هذا الاتصال المبعثر ترابط أقل من الطبقة المترابطة بالكامل، مما يؤدي إلى تخزين وزن أقل. في طبقة متصلة بالكامل، يكون كل وزن مستقال عن الآخر، مما ينتج عنه كميات كبيرة من ت خزين وتسوية قيم كثيرة. ومع ذلك، في الطبقة الالتفافية، تكون الأوزان مشتركة ألن الأوزان هي القيم في الفلتر. في كل مرة يتم إجراء تبديل لمنطقة معينة من الادخال يتم إجراؤه بنفس الفلتر، وبالتالي تكون الأوزان هي نفسها من الممكن استخدام نوى متعددة في الطبقة الالتفافية. يمكن استخدام النواة كفلتر الاكتشاف نمط صغير معين في صورة الادخال باستخدام نوى متعددة، يمكن البحث في أنماط صغيرة متعددة في وقت واحد.

تحديات CNN:

على الرغم من أن شبكات CNN العميقة قد حققت أداء جيدا في معالجة البيانات المهيكلة فضائياً إلى أن هناك بعض التحديات التي تواجه عملية التدريب لهذه الشبكات والتي تم سردها أدناه :
تشبه شبكات CNN العميقة بشكل عام الصندوق الأسود، لذا ال يوجد تفسير لها. لذلك أحيانا يصعب دراستها. يمكن أن يؤدي تدريب CNN على بيانات الصور عالية الضوضاء إلى زيادة خطأ التصنيف. يمكن أن تؤدي إضافة قدر صغير من الضوضاء العشوائية إلى صورة الادخال إلى خداع الشبكة إلى تصنفي مختلف. تعتمد شبكات CNN العميقة على التعلم الخاضع لإشراف، لذا فهم بحاجة إلى بيانات ضخمة للتعلم

اختيار المعامل الفائق المناسب له تأثير كبير على أداء CNN بشكل صحيح.

10.1 معمارية الشبكات العصبونية الالتفافية (CNN):

- الهيكلية:
تم تصميم شبكات العصبية المتسلسلة (CNN) لمحاكاة معالجة الرؤية في الدماغ البشري. تتألف من طبقات الطي، وطبقات التجميع، والطبقات المتصلة بالكامل. تعلم طبقات الطي أنماطًا محلية وتسلسلات من الميزات، بينما تقوم طبقات التجميع بتصغير الأبعاد الفضائية وتقليل الحساب.

- تعلم الميزات:
تتعلم شبكات CNN الميزات بشكل تسلسلي وتلقائي من البيانات. تعمل طبقات الطي والتجميع كمستخرجات للميزات، حيث تلتقط تدريجيًا حواف المستوى المنخفض والملمس والميزات على مستوى أعلى.

- مشاركة المعلمات:
تستخدم شبكات CNN مشاركة الوزن والانحياز المشترك في طبقاتها ، مما يتيح لها تعلم الميزات المحلية التي تكون مكافئة للترجمة. تقلل هذه المشاركة من حاجة لعدد كبير من المعلمات وتسرع عملية التدريب.

10.2 التعلم بالنقل – Transfer Learning :

يمكن إعادة استخدام شبكات ال CNN المدربة مسبقاً على مجموعات بيانات كبيرة من الصور (مثل ImageNet) كنقطة بداية من أجل مهمة آخري متعلقة بالمهمة الأساسية وهذا يسرع بشكل كبير من عملية التدريب ويحسن الأداء على مجموعات بيانات أصغر.

بشكل عام، تعتبر شبكات ال (CNN) فعّالة جدًا لمهام رؤية الحاسوب بفضل قدرتها على تعلم الميزات ذات الصلة من الصور تلقائيًا، ومشاركة المعلمات(Parameters)، واستغلال الأبعاد الفضائية. أما هندسة التعليم العميق التقليدي فهي أكثر تنوعًا ولكن يمكن أن تكون معقدة لتحسين المهام البصرية المعقدة، وقد تتطلب معالجة متقدمة للبيانات وضبط معلمات مستمر.

10.3 فرط التكيف/التعلم - Overfitting :

هو سلوك أو نتيجة غير مرغوبة أبداً من مبدأ تدريب الآلة
حيث يعطي النموذج المدرب توقعات دقيقة جدا للبيانات المدربة فقط على عكس التوقعات الخاصة بالبيانات الجديدة حيث تكون غير دقيقة،
وبالتالي لا يستطيع النموذج تعميم البيانات – "Generalization"

- **أهمية شبكات ال CNNs في التطبيقات الحديثة**

التصنيف الصوري :
القدرة على تحديد محتوى الصور وتصنيفها بدقة، مثل تمييز الحيوانات والأشياء والوجوه.

اكتشاف الكائنات :
القدرة على اكتشاف وتحديد مواقع الكائنات داخل الصور، وهو مفيد لتطبيقات مثل تتبع الكائنات والأمان.

الرؤية الحاسوبية:
تحسين القدرة على تحليل وفهم الصور، وذلك بفحص الميزات المكتشفة في الصور.

11 الرؤية الحاسوبية

الرؤية الحاسوبية Computer Vision هي من مجالات علوم الحوسبة الحديثة، وشكل من أشكال الذكاء الاصطناعي، تساعد هذه التقنية على رؤية
العالم وتحليل البيانات المرئية ثم اتخاذ قرارات منها أو اكتساب فهم حول البيئة والعالم، بالإضافة إلى تحديد
ومعالجة الأشياء مثل الصور ومقاطع الفيديو بنفس الطريقة التي يفعلها البشر. المهمة التقليدية في الروية الحاسوبية، جميع الطرق الموجودة لحل هذه المسألة تقوم بإيجاد أفضل الحلول:

11.1 المهام الرئيسية للرؤية الحاسوبية

- **التمييز - Recognition:**

من أجل إيجاد أشكال معينة كالأشكال الهندسية، وجوه الأشخاص، الأحرف المطبوعة أو المكتوبة، أو السيارات
وفي حالات معينة فقط محددة على الغالب بظروف إضاءة محددة، خلفية ووضعية معينة للجسم بالنسبة للكاميرا.

- **التعرف:**

يتم التعرف على واحد أو البعض من الأجسام التي تم تعليمها مسبقاً للحاسوب، غالباً بأوضاعها المختلفة أو بزوايا مختلفة للكاميرا.

- **التحديد:**

تحديد مطابق وحيد للجسم المعرف. مثلاً: تحديد وجه شخص معين أو التعرف على بصمة شخص معين أو سيارة من نوع معين.

التتبع – Tracking :

تتبع حركة الأجسام في الصورة المتعاقبة زمنياً (فيديو) مثل تتبع الأشخاص أو السيارات.

- **الحركة - Movement:**

يوجد العديد من المهام التي تتعلق بتقدير الحركة حيث تعالج فيها سلسلة من الصور المتعاقبة زمنياً من أجل
حساب السرعة إما عند كل نقطة في الصورة أو في المشهد الثلاثي الأبعاد.
بعض الأمثلة على هذه المهام هي:
حركة الكاميرا :تحديد الحركة الصلبة للكاميرا في الفضاء الثلاثي الأبعاد.

أنظمة الرؤية الحاسوبية:

تختلف أنظمة الرؤية الحاسوبية بشكل كبير وتتوزع بين أنظمة كبيرة ومعقدة تؤدي مهمات عامة

وشاملة، وبين أنظمة صغيرة تؤدي مهمات مخصصة وبسيطة ولكن معظم أنظمة الرؤية الحاسوبية

تشمل العناصر التالية بشكل أساسي:

الحصول على الصورة:
يتم الحصول على الصورة باستخدام واحد أو أكثر من مستشعرات الصور، وهذه تتضمن العديد من كاميرات مستشعرات الضوء، مستشعرات المسافات أجهزة التصوير الشعاعي الرادار كاميرات الموجات الفوق صوتية. وتبعا لنوع المستشعر فإن الصورة الناتجة تكون ثنائية البعد أو ثلاثية البعد أو سلسلة صور متعاقبة.

استحصال معالم الصورة Feature Extraction
يتم الحصول على معالم الصورة على مستويات دقة مختلفة من بيانات الصورة ذاتها تصنف هذه المعالم إلى:

- **معالم عامة** :Global Features مثل اللون والشكل.
- **معالم محلية** Local Features كشف الزوايا، والبقع.
- **التحري التقسيم** :Detection/segmentation يتم تحديد أي نقاط أو مناطق من الصورة هي المناطق الهامة من أجل العمليات اللاحقة.

مثلاً: تقسيم صورة أو أكثر تحتوي على المنطقة التي تحتوي الجسم المهتم به.

أمثلة حول تطبيقات الرؤية الحاسوبية :

- **المركبات ذاتية القيادة.**
- **تطبيق جوجل للترجمة.**
- **التعرف على الوجه.**

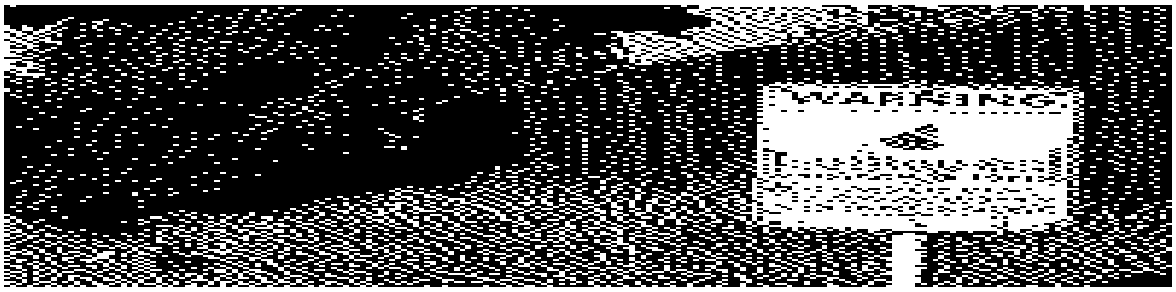
11.2 أنواع الصور:

11.2.1 الصورة الرقمية:

هي تمثيل الصور ثنائية الأبعاد على الحاسوب بواسطة الصفر والواحد (01) تتكون كل صورة رقمية على الكمبيوتر من البيكسل وهو أصغر وحدة في الصورة وكل صورة هي مصفوفة تحتوي على صفوف وأعمدة من البكسلات وكلما زادت عدد البكسلات كلما كانت الصورة أوضح وتنقسم الصور الرقمية إلى:

11.2.2 الصورة الثنائية - Binary Image:

وهي الصورة التي تحتوي على اللونين الأبيض والأسود فقط وتحمل كل بيكسل بها إما الصفر أو الواحد.



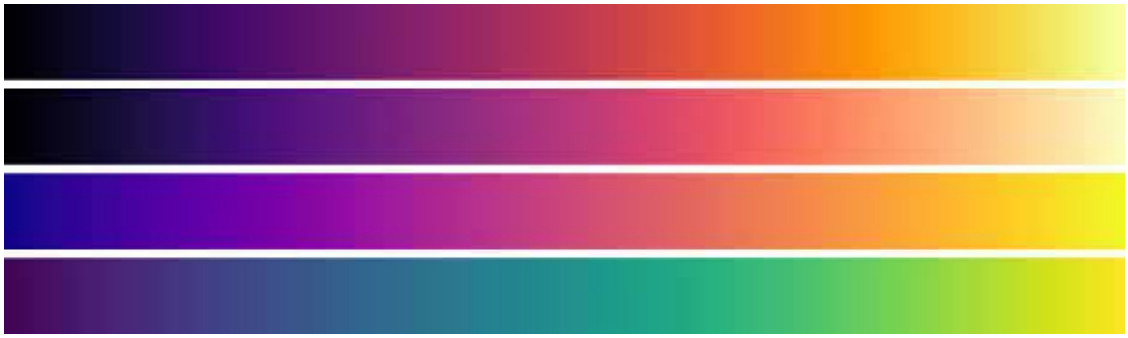
11.2.3 الصور الرمادية - Grayscale Image:

وهي الصورة التي تحتوي أبيض وأسود مع تدرجات الرمادي وتمثل شدتها بأرقام من 0 إلى 255 حيث يمثل الواحد اللون الأبيض والشدة عندما تكون 255 فإن اللون البيكسل يكون أسود وعند تمثيل هذه الصورة على الكمبيوتر تمثل أعمدة متساوية وصفوف متساوية من البكسلات كل بيكسل بها 8bits تحدد الشدة من 0 إلى 255



11.2.4 الصور الملونة - Colored Image:

هي الصور الرقمية التي تدعم الألوان عن طريق تخصيص ثلاث خانات بكل بيكسل لتحديد شدة الثلاثة ألوان الأساسية (الأحمر – الأخضر - الأزرق)
حيث كل خانة تحتوي 8Bits للكتابة عليها أي أن هناك 24Bits بكل بيكسل

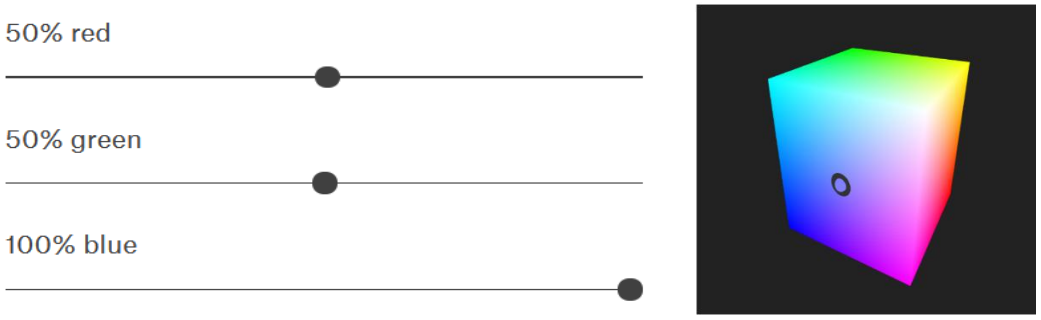


11.3 نماذج الصور – Color Models:

- لا يعد نموذج ألوان RGB نموذجًا بديهيًا بشكل خاص لإنشاء الألوان في التعليمات البرمجية.
على الرغم من أنك قد تكون قادرًا على تخمين مجموعة القيم التي ستستخدمها لبعض الألوان مثل الأصفر (كميات متساوية من الأحمر والأخضر) أو اللون الأحمر المستخدم في إعلان ما يصعب تخمين الألوان غير النقية في نموذج الألوان هذا.
ما هي القيم التي ستستخدمها للون الأرجواني الداكن؟ ماذا عن العثور على اللون المكمل للسماوي؟ إذا لم تتمكن من العثور على الإجابة، فذلك لأن البشر لا يفكرون في الألوان على أنها مزيج من الأضواء الحمراء والخضراء والزرقاء.
- النموذج اللوني هو تمثيل مرئي يصور طيف الألوان كنموذج متعدد الأبعاد. تحتوي معظم نماذج الألوان الحديثة على 3 أبعاد (مثل RGB)، وبالتالي يمكن تصويرها كأشكال ثلاثية الأبعاد، في حين أن النماذج الأخرى لها أبعاد أكثر (مثل CMYK).
فيما يلي، سنلقي نظرة على نماذج الألوان RGB وHSV وHSL، والتي تنتشر جميعها في أدوات التصميم الرقمي ولغات البرمجة الحالية. تستخدم جميع نماذج الألوان هذه نفس ألوان RGB الأساسية، مما يجعلها أمثلة جيدة لكيفية تصور نماذج الألوان لنفس طيف الألوان بأبعاد مختلفة على نطاق واسع.

11.3.1 نموذج RGB:

RGB هو نموذج ألوان ذو ثلاثة أبعاد - الأحمر والأخضر والأزرق - يتم مزجها لإنتاج لون معين.
عند تحديد الألوان في هذه الأبعاد، يجب معرفة تسلسل الألوان في طيف الألوان، على سبيل المثال: أن مزيج 100% من الأحمر والأخضر ينتج اللون الأصفر. غالبًا ما يتم تصوير نموذج ألوان RGB على شكل مكعب عن طريق تعيين الأبعاد الحمراء والخضراء والزرقاء على المحاور x وy وz في مساحة ثلاثية الأبعاد.
يتم توضيح ذلك في المثال أدناه، حيث يتم تمثيل جميع مزيج الألوان الممكنة داخل حدود المكعب.



HSV Model 11.3.2

نموذج **HSV**هو أحد نماذج تمثيل الألوان في الحاسوب والرؤية الحاسوبية، ويُستخدم كثيرًا لأنه أقرب إلى طريقة إدراك الإنسان للألوان مقارنةً بـ.RGB

- **HSV** ◇ اختصار لـ:

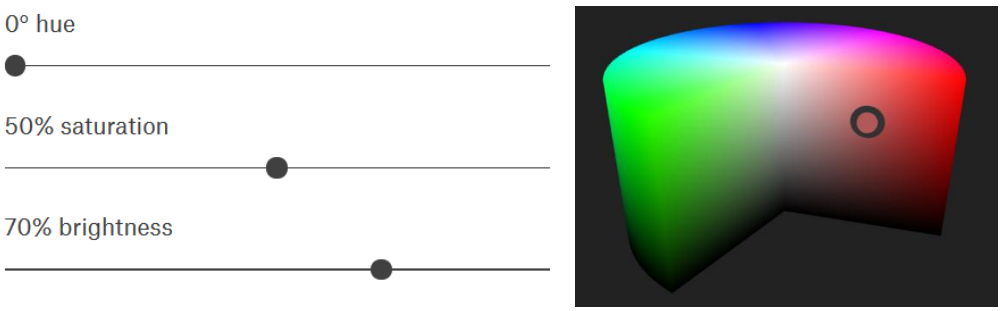
- **H – Hue الصبغة اللونية :**(تمثل اللون نفسه (أحمر، أزرق، أخضر...)، ويُقاس عادةً بالدرجات من 0° إلى 360° على عجلة الألوان.
- **S – Saturation التشبّع :**(يحدد مدى نقاء اللون أو شدته. عند 100% يكون اللون نقيًا تمامًا، وعند 0% يصبح اللون رماديًا.
- **V – Value القيمة أو السطوع :**(تمثل درجة الإضاءة أو السطوع في اللون، حيث 0% يعني أسود تمامًا و100% يعني أقصى سطوع ممكن لذلك اللون.

- **الفكرة :**

يمكنك تخيل HSV كـ **أسطوانة ألوان:**

- الزاوية حول المحور تحدد **الصبغة.(Hue)**
- المسافة من المركز تحدد **التشبّع.(Saturation)**
- الارتفاع على المحور يحدد **القيمة/السطوع.(Value)**

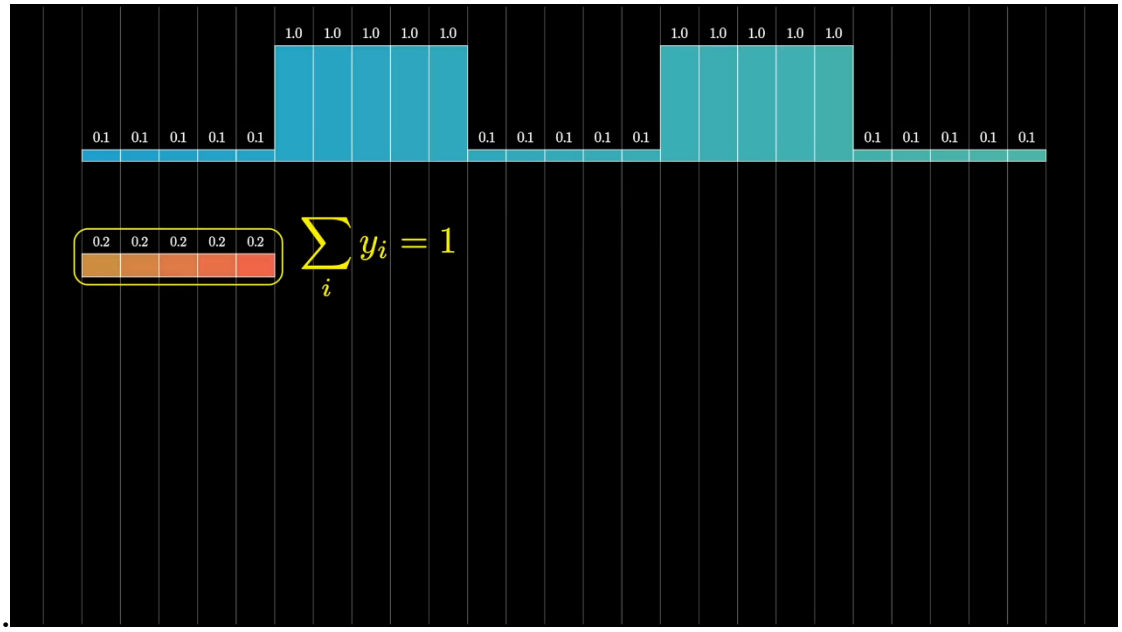
يُستخدم نموذج HSV بكثرة في **معالجة الصور**، مثل اختيار الألوان في برامج التصميم، أو فصل الألوان في الرؤية الحاسوبية، لأنه يسهل التحكم في اللون بمعزل عن السطوع أو التشبع.



12 مفهوم عملية الطي الرياضي:

في الرياضيات (بالتحديد في تحليل الدوال) , الطي هي عملية رياضية تطبق على دالتين (f)&(g) وتنتج دالة ثالثة تعبر عن كيفية تعديل شكل إحدى الدوال بواسطة الأخرى.
"تمهيد البيانات" يشير إلى عملية تقليل أو القضاء على التباينات ذات التردد العالي أو الضوضاء في مجموعة البيانات. يمكن أن يكون ذلك مفيدًا بشكل خاص عند التعامل مع بيانات ضجيجيه أو متقلبة، خصوصًا في البيانات الزمنية أو أنواع أخرى من البيانات المستمرة حيث تتسبب التقلبات الصغيرة أو التقلبات العشوائية في صعوبة تحديد الاتجاهات أو الأنماط الأساسية.
المتوسط المتحرك هو تقنية شائعة تُستخدم لتمهيد البيانات. إليك كيف يعمل:
(Sliding Window) في المتوسط المتحرك، تحدد نافذة بحجم ثابت (يُسمى غالبًا "حجم النافذة" أو "طول النافذة") تنزلق أو تتحرك عبر مجموعة البيانات.

حساب المتوسط:
في كل موقع للنافذة، يحسب المتوسط لنقاط البيانات داخل تلك النافذة



الشكل: 11 - 1 حساب المتوسط

استبدال البيانات الأصلية:
يصبح المتوسط المحسوب القيمة الجديدة لهذا الموقع.
مع تحرك النافذة، يتم استبدال كل نقطة بيانات في مجموعة البيانات الأصلية بمتوسط النقاط في نافذتها المقابلة.
تُقلل هذه العملية بشكل فعال من تأثير نقاط البيانات الصاخبة الفردية، حيث يقوم العملية المتوسطية بتمهيد أي تغييرات وتقلبات مفاجئة ضمن النافذة. كلما كان حجم النافذة أكبر، زاد التمهيد، ولكنه أيضًا

يُدخل المزيد من التأخير في اكتشاف التغييرات الفعلية في البيانات.

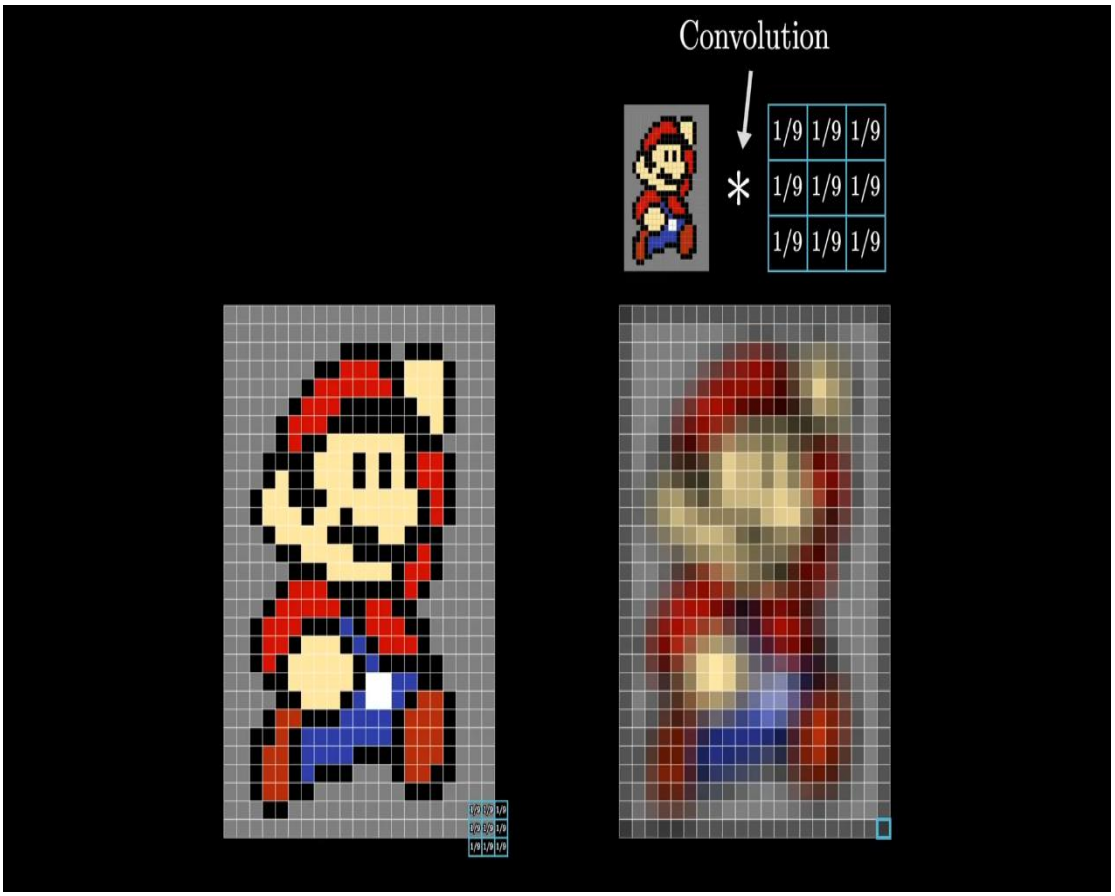
من خلال تمهيد البيانات، يمكننا أن نُسهل تحديد الاتجاهات والأنماط أو التغييرات الأساسية على مر الزمن. هذا مفيد بشكل خاص في الحالات التي نرغب في التركيز على سلوك البيانات العام بدون الانحراف بسبب الضوضاء على النطاق الصغير التي قد لا تحمل معلومات كبيرة.

يجب مراعاة بأن التمهيد يمكن أن يكون قيمًا، لذا يجب اختيار حجم النافذة المناسب.

النافذة صغيرة قد لا تمهد البيانات بشكل فعال، في حين أن نافذة كبيرة قد تُمهد البيانات بزيادة، مما قد يحجب التفاصيل الهامة أو يؤدي إلى تأخير في اكتشاف التغييرات الفعلية. يجب أن يتم اختيار حجم النافذة استنادًا إلى خصائص البيانات الخاصة بك وأهداف التحليل المحددة.

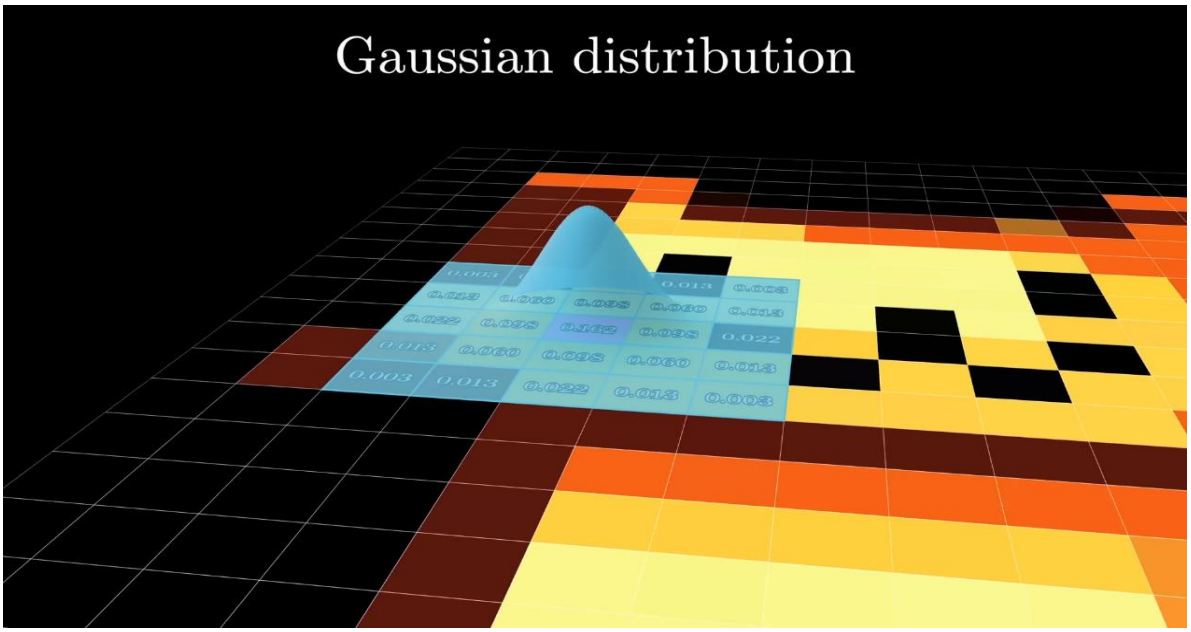
Gaussian Blur

إن تطبيق 2-Dimensional Analog يعطي نوع ما من Blur للصور يمكن القول إن الصورة على اليمين هي الصورة المطوية للصورة الأصلية مع هذه الشبكة الصغيرة من القيم التي تدعى بال Kernel

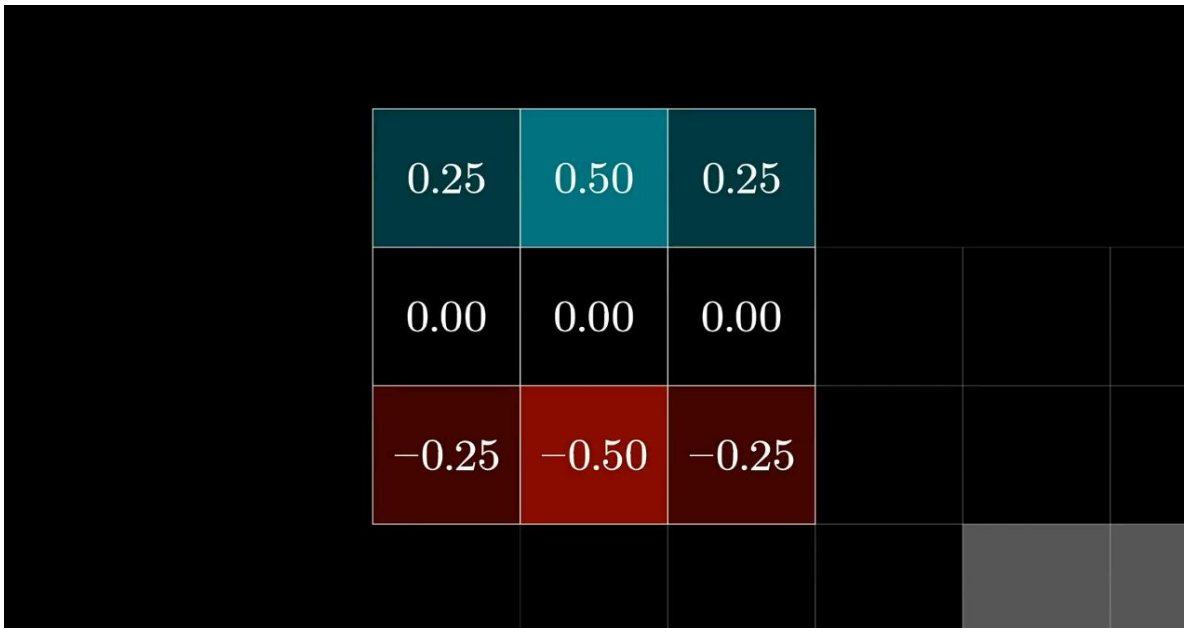


الشكل: 11 - 2 تطبيق فلتر ضبابي

ممكن اختيار Kernel أخر ب قيم أو حجم مختلف لتحسين جودة ال blurring أو تطبيق ما يسمى ب Gaussian Blur بإعطاء وزن أكبر للبيكسل المركزي وقيم أصغر وأصغر باتجاه الحواف والذي بدوره يعطي تأثير أفضل بكثير من ال kernel السابق:



وبالتالي السؤال ماذا يفعل ال Kernel التالي للصورة ما هو التغيير الذي قد يحدثه. مثال:



ممكن القول إن هذا الفلتر يحدد أو يتعرف على بعض الميزات الأفقية.

إن عملية التدريب شبكات ال CNN تتمحور بشكل خاص حول إيجاد قيم ال Kernels الخاصة بالتعرف على ميزات الصورة.

13 خريطة الميزات – Features Map:

- في شبكاتCNN ، خريطة الميزات هي ناتج طبقة التصفية تُمثل الميزات المحددة في صورة الإدخال أو خريطة الميزات.

- أثناء التمرير الأمامي لشبكةCNN ، يتم طبق الصورة الإدخال أو أكثر بمرشحات واحدة أو أكثر لإنتاج خرائط ميزات متعددة.

كل خريطة ميزات تتوافق مع مرشح معين وتُمثل استجابة تلك المرشح لصورة الإدخال. يُمثل كل عنصر في خريطة الميزات تنشيط عصبة معينة في الشبكة، وقيمته يمثل درجة وجود الميزة المقابلة في صورة الإدخال.

- على سبيل المثال، في الطبقات الأولى لشبكةCNN ، قد تُمثل خرائط الميزات ميزات على مستوى منخفض مثل الحواف والخطوط والزوايا.

أما مع التقدم داخل الشبكة، قد تُمثل خرائط الميزات ميزات أكثر تعقيدًا مثل الأشكال والملمس أو حتى الكائنات بأكملها:

عدد خرائط الميزات في طبقة التصفية هو معلم تكييف يمكن ضبطه أثناء تصميم الشبكة.

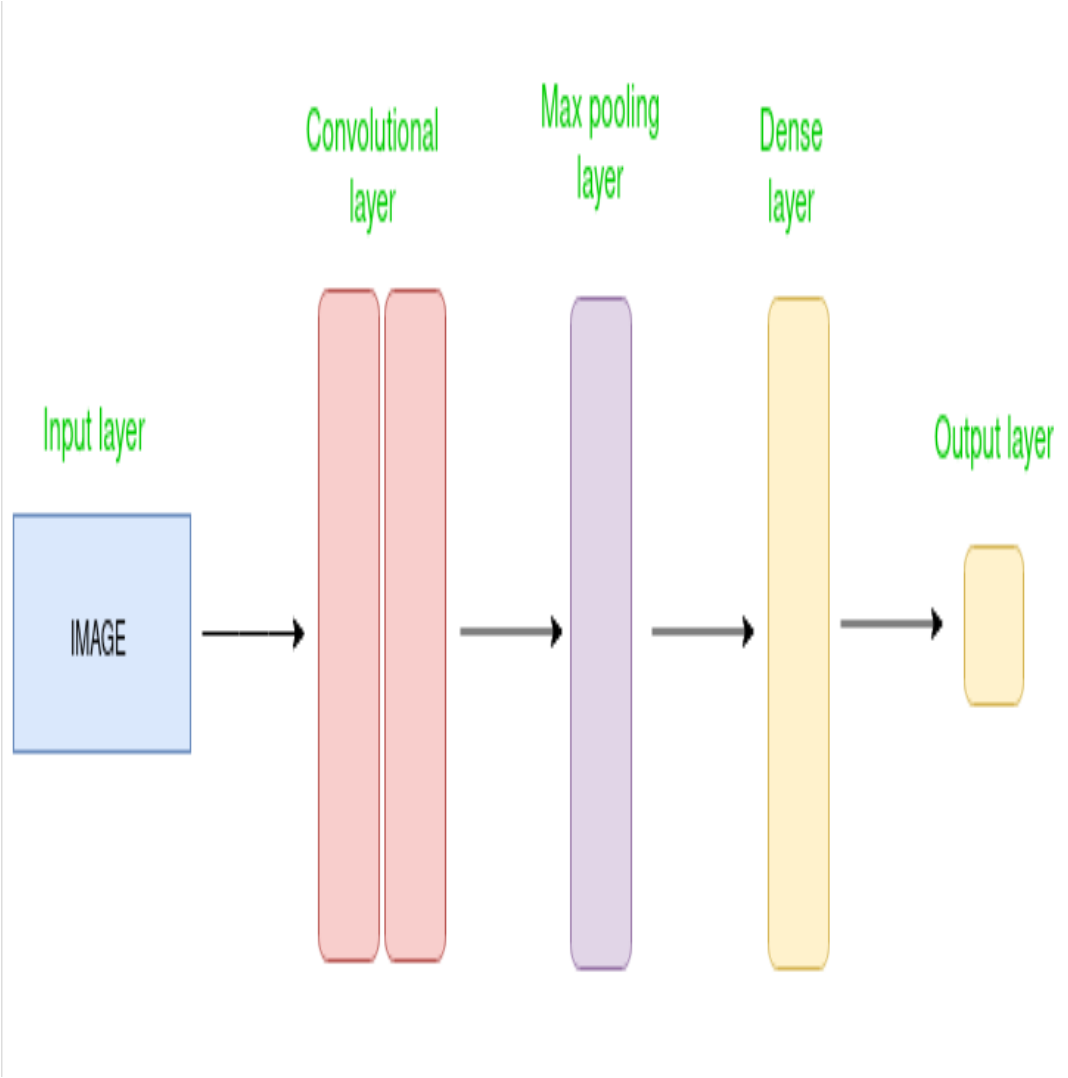
زيادة عدد خرائط الميزات يمكن أن تساعد الشبكة في تعلم ميزات أكثر تعقيدًا ومجردة، ولكنها تزيد أيضًا من التكلفة الحسابية وقد تؤدي إلى الاعتماد المفرط إذا كانت الشبكة كبيرة جدًا.

بعد كل طبقة تصفيات، تُطبَّق توابع التفعيل غير الخطية مثل (ReLU) عادةً لإدخال اللاخطية إلى خرائط الميزات.

بعد ذلك، يتم استخدام طبقات التجميع لتقليل الحجم الفضائي لخرائط الميزات مع الحفاظ على أهم المعلومات.

14 شرح عن خصائص أو طبقات ال CNN:

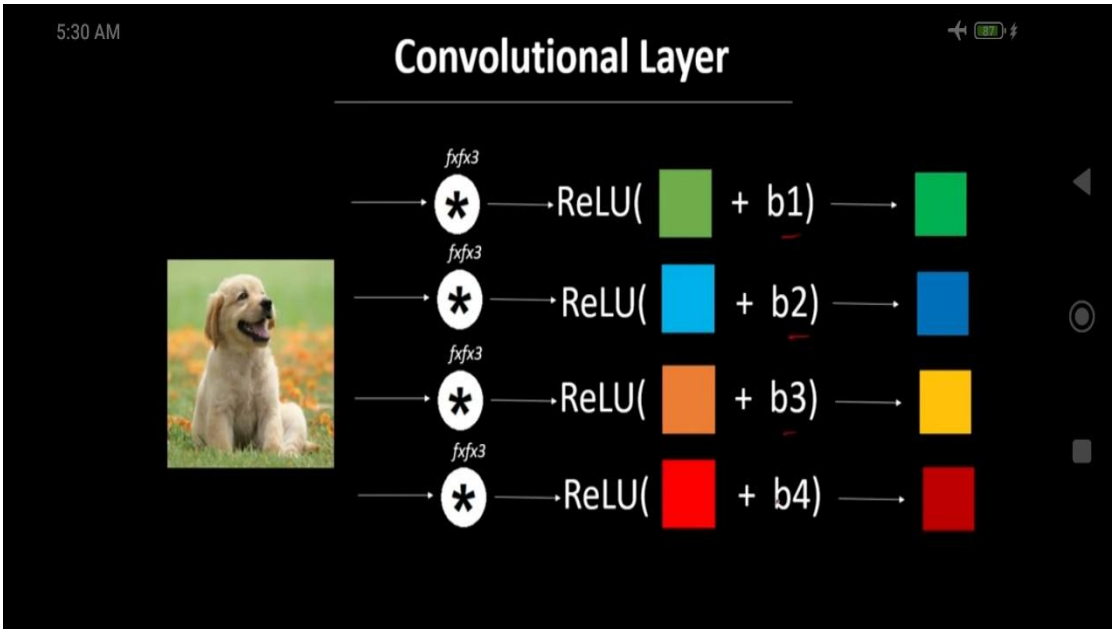
14.1 بنية الشبكة:



الشكل: 13 - 1 بنية شبكة ال CNN

14.2 طبقات الطي – Convolution Layers:

يتم تطبيق فلتر أو أكثر على الصورة/ الصور المدخلة حسب بنية النموذج بعدها تطبيق RELU Function+bias وتكون النتيجة خارطة ميزات أولية



14.3 خطوة الانزلاق - Stride:

stride or strided convolution مقدار تحريك الفلتر ....1,2,3 (بيكسل)

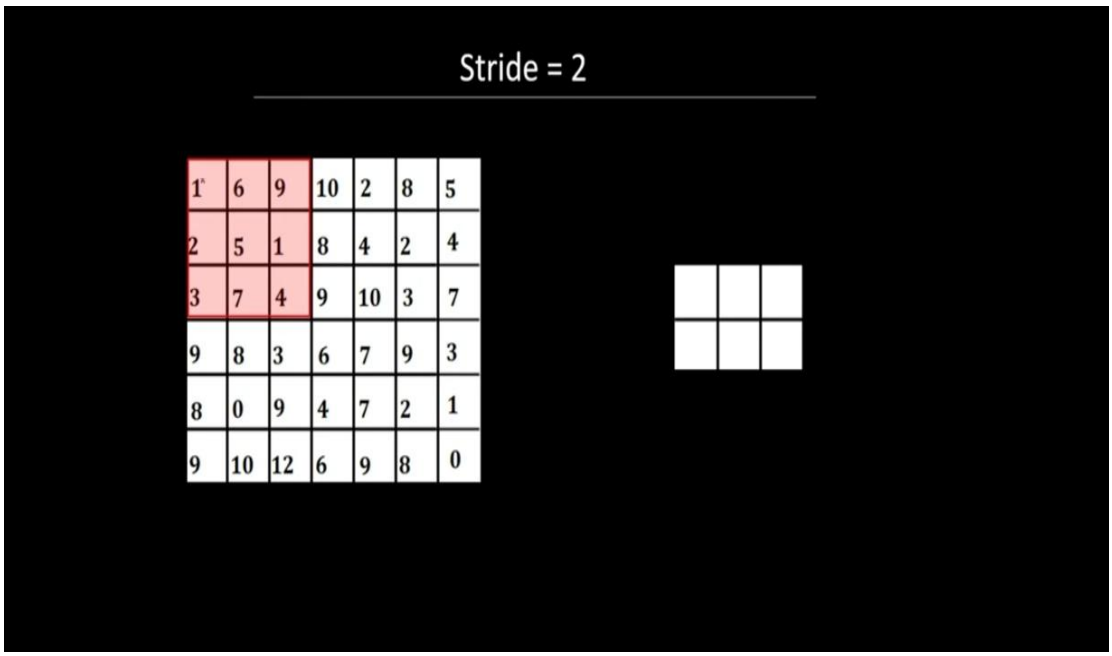
يكون الخرج يساوي 1+ (n-t/s)

حيث:

n هي حجم الصورة

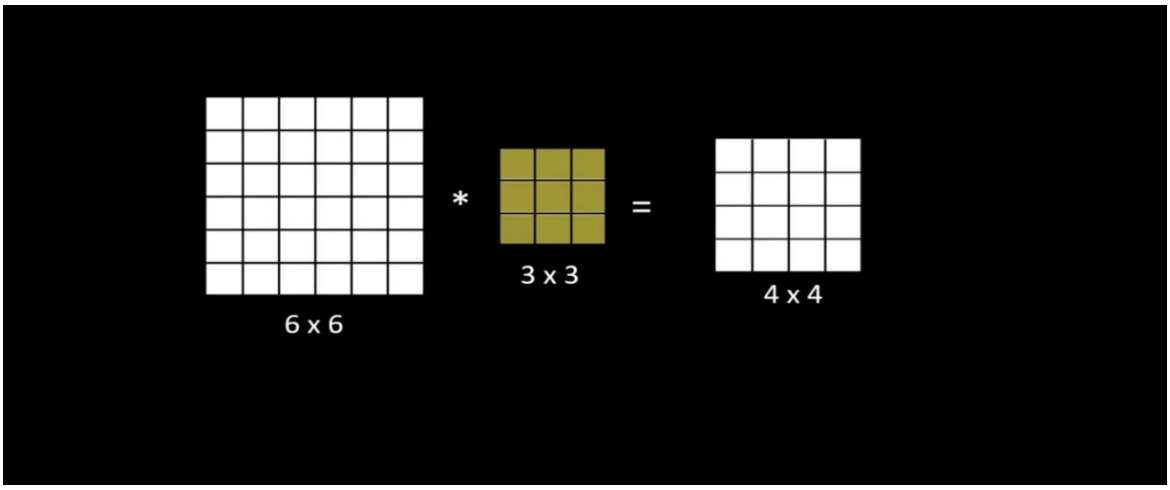
t هي حجم الفلتر

s مقدار خطوة الانزلاق Stride

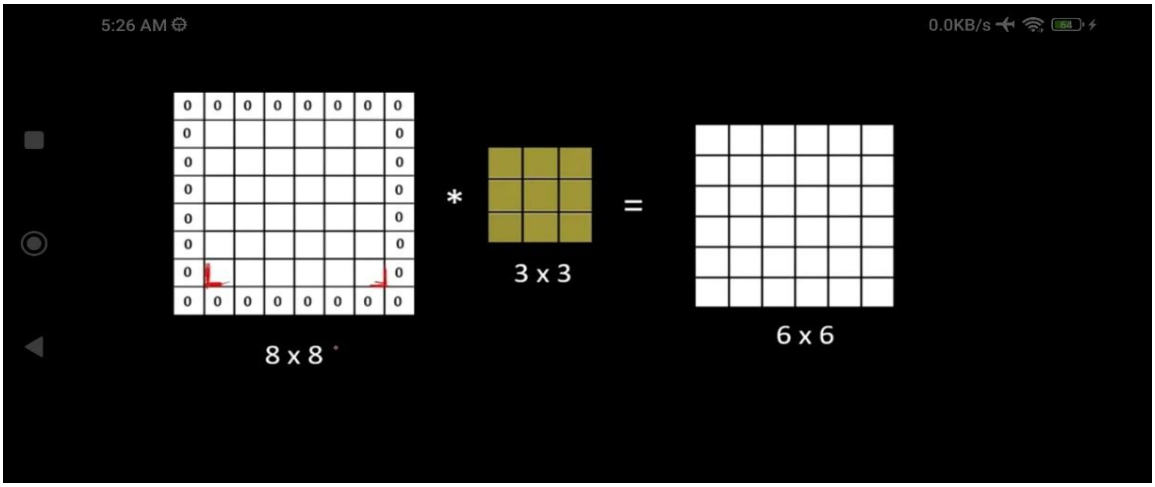


14.4 الحشو - Padding:

عند تطبيق عدة طبقات من ال convolution نلاحظ أن حجم الصورة الأصلية يقل تدريجيا مع كل طبقة وبالتالي هذا يعني ضياع الميزات



لحل هذه المشكلة نستخدم بما يعرف بالحشو (padding) :



بحيث إذا أردنا الحفاظ على حجم الصور نستخدم :

1- Same Convolution

Tf.nn.conv2d(X, W1, Stride = [1,1,1,1], padding = 'same)

أما إذا أردنا غير ذلك أي عدم الحفاظ على حجم الصورة الأساسية نستخدم

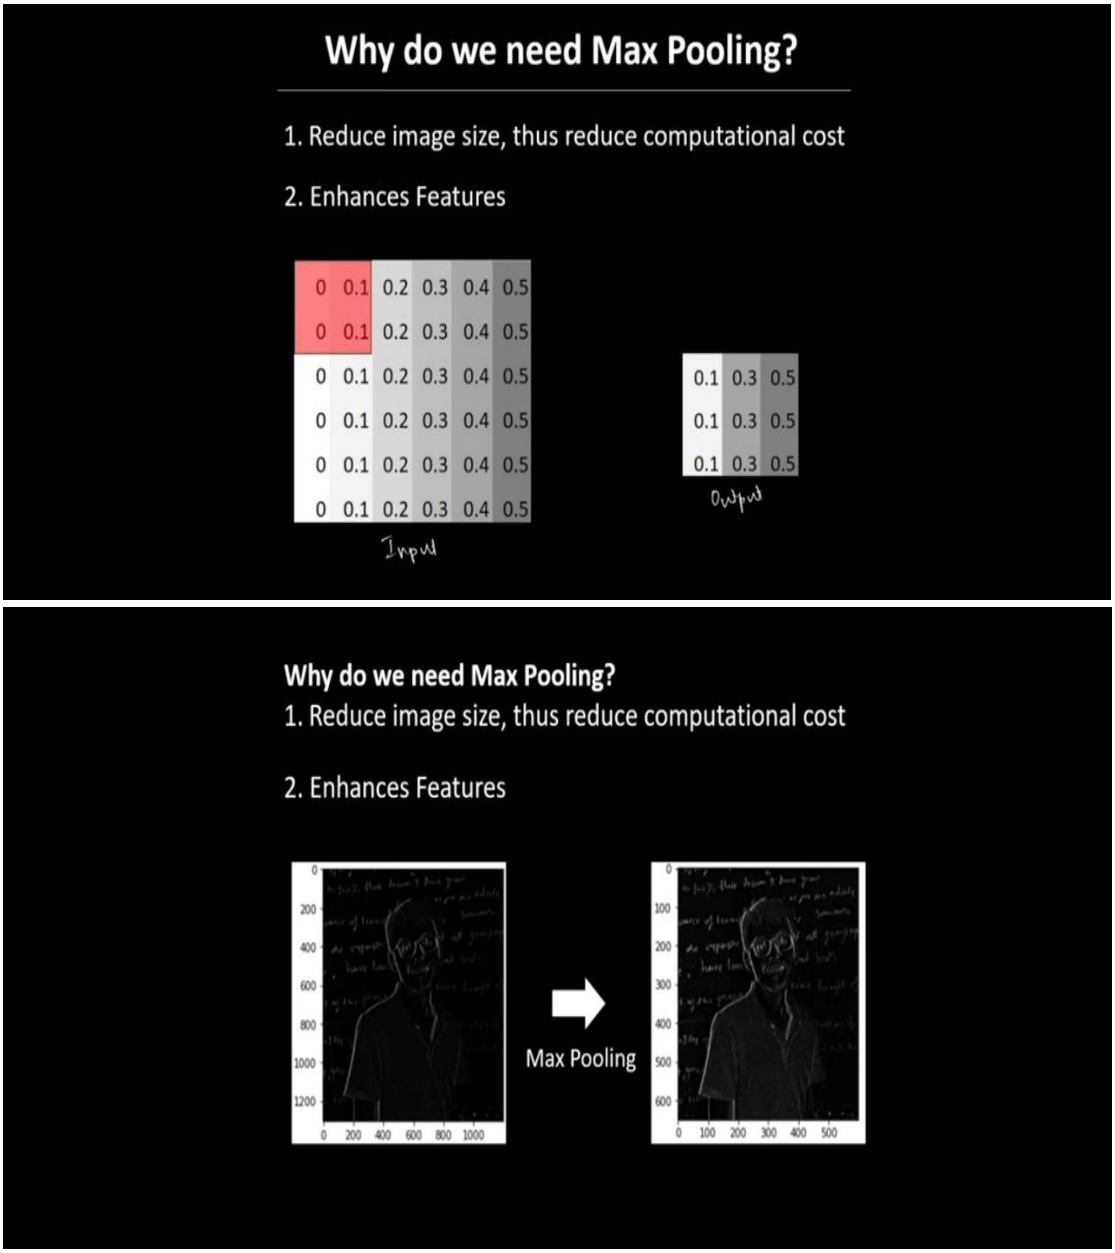
2- Vaild Convolution (no padding applied)

Tf.nn.conv2d(X, W1, Stride = [1,1,1,1], padding = 'valid')

14.5 التجميع الأقصى – Max Pooling :

عملية تقليل أبعاد الميزة (feature map) عن طريق أخذ أكبر قيمة في كل نافذة فرعية، مما يحافظ على أهم المعلومات.

تطبق ال MaxPooling بعد تطبيق أحد ال Kernels على الصورة المدخلة تعطي خارطة ميزات Feature Map أصغر محسنة أي أنها تخفض الكلفة الحسابية مع تعزيز التعرف على ميزات ما للصورة



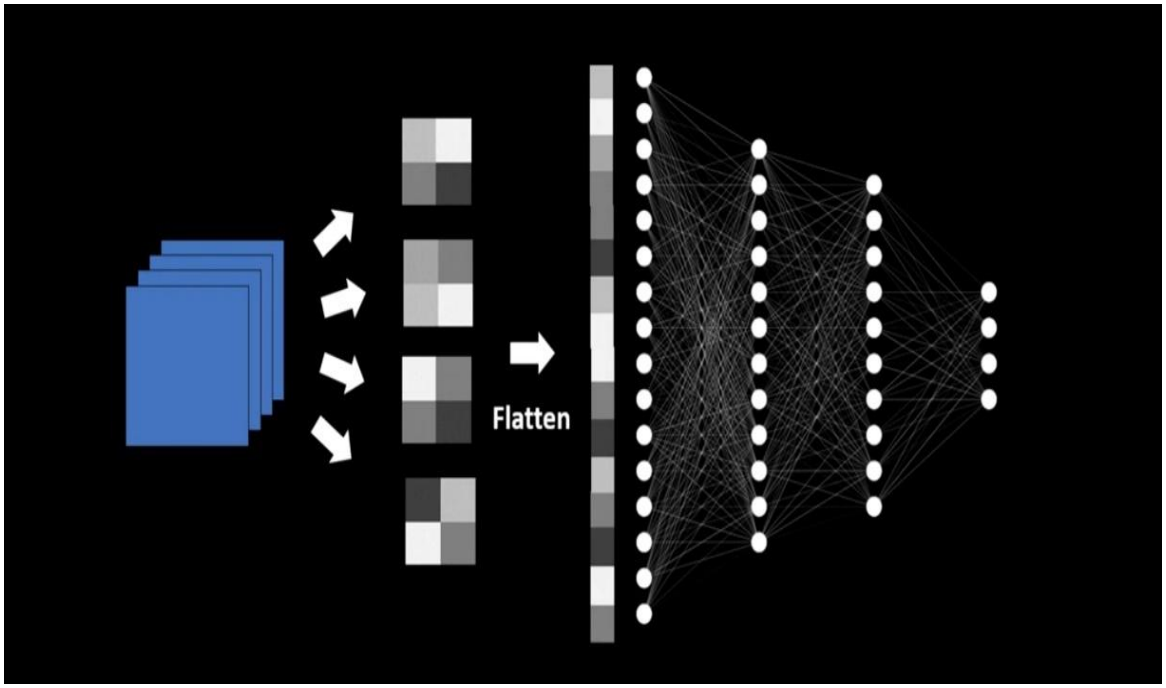
الشكل: 13 - 1 تطبيق Maxpooling لتوضيح السمات

14.6 توليد مصفوفة أحادية – Flattening :

بعد الانتهاء من تطبيق طبقات الطي و ال MaxPooling يتم تحويل البيانات ثلاثية الأبعاد إلى مصفوفة أحادية الأبعاد لوصلها بطبقة ال fully-connected

14.7 طبقة كاملة الاتصال – Fully-Connected layer :

عبارة عن طبقة الخرج النهائية التي تعطي Y_pred بعد استخدام طبقات الطي لاستخراج مختلف أنواع الميزات أي أنها تقوم بعمل Classification لل output



الشكل: 13 - 2 توضيح طبقة Flattening and Fully Connected

---

15 نظرة عامة حول الشبكات التوليدية الخصمية(GANs)

generative adversarial network

مقدمة:(Introduction)

ظهرت الشبكات التواليدية الخصمية لأول مرة سنة **2014** على يد الباحث **إيان غودفيلو (Ian Goodfellow)** وفريقه البحثي. ومنذ ذلك التاريخ،
أصبحت من أكثر النماذج ثورية في الذكاء الاصطناعي العميق (Deep Learning)،
حيث فتحت الباب أمام أنظمة قادرة ليس فقط على التعرف على البيانات كما تفعل الشبكات التقليدية، بل **على توليد بيانات جديدة تبدو واقعية لدرجة يصعب التمييز بينها وبين البيانات الحقيقية**.
الفكرة الجوهرية لـ GAN تتمثل في وجود **نموذجين عصبيين يتنافسان فيما بينهما:**

- الأول **المولّد (Generator)** يحاول أن يصنع بيانات جديدة مزيفة لكن واقعية (صور وجوه، أصوات، نصوص...).
- الثاني **المميّز (Discriminator)** يحاول كشف ما إذا كانت البيانات المدخلة حقيقية (من مجموعة البيانات الأصلية) أم مزيفة (من إنتاج المولّد).

هذه العلاقة التنافسية بين المولّد والمميّز تُشبه لعبة "القط والفأر"، حيث يسعى كل طرف لتحسين أدائه في مواجهة الآخر، مما يؤدي مع الوقت إلى إنتاج بيانات عالية الجودة تتفوق على كثير من النماذج السابقة في مجال **التعلم التوليدي.(Generative Learning)**

15.1 مميزات وعيوب الشبكات التوليدية الخصمية:(Pros & Cons)

المميزات:

1. **القدرة على التوليد عالي الجودة:(High Fidelity Generation)**
أثبتت شبكات GANs قدرتها على إنتاج صور عالية الدقة لا يمكن للبشر غالبًا التمييز بينها وبين الصور الحقيقية.
2. **المرونة:(Versatility)**
يمكن تطبيقها على الصور، الفيديو، الصوت، النصوص، بل وحتى على البيانات ثلاثية الأبعاد (3D).
3. **الاستفادة من بيانات محدودة:**
في بعض الحالات، يمكن لـ GANs أن تساعد في **زيادة البيانات (Data Augmentation)** عبر توليد عينات إضافية تحسّن أداء نماذج أخرى.
4. **التطبيقات المتقدمة:**
   - تحويل الصور من نمط لآخر (Image-to-Image Translation) مثل تحويل رسمة إلى صورة حقيقية.
   - تحسين الصور ذات الجودة المنخفضة.(Super Resolution)
   - توليد الوجوه والأشكال الافتراضية.(Deepfake, Avatars)

العيوب:(Cons / Limitations)

1. **صعوبة التدريب:(Training Instability)**
من أشهر مشاكل GANs أنها صعبة التدريب؛ قد ينهار المولّد (Mode collapse) وينتج صورًا متشابهة باستمرار.
2. **حساسية للأداء والمعمارية:**
اختيار دوال التفعيل (Activation Functions) أو المهيّئات (Optimizers) له تأثير ضخم على النتائج.
3. **غياب مقياس واضح للتقييم:(Evaluation Metrics)**
من الصعب تقييم جودة العينات المُولدة عددياً؛ وغالبًا يعتمد الباحثون على مقاييس مثل **Inception Score (IS)** أو **Fréchet Inception Distance (FID).**

4. **تكلفة حاسوبية عالية:**
تدريب GANs يتطلب وقتًا وموارد حسابية (GPU/TPU) كبيرة، خاصة مع الصور عالية الدقة.

لماذا يُوصى باستخدام GANs على شبكات أخرى؟

- بالمقارنة مع النماذج الإحصائية التقليدية أو الشبكات التوليدية الأخرى مثل **Variational Autoencoders (VAEs)**، توفر GANs **دقة بصرية وواقعية أعلى** في إنتاج الصور.
- تميل **VAEs** إلى إنتاج صور "مُطموسة" أو غير واضحة بسبب طبيعة الخسارة الاحتمالية، بينما GANsتنتج صورًا أكثر حدة وواقعية.
- على عكس الشبكات التقليدية التي تكتفي بالتعلم من البيانات لتصنيفها أو تقدير قيم معينة، تقدم GANs **إمكانات إبداعية (Creative Capabilities)** تجعلها مرشحة مثالية في الفن الرقمي، صناعة الألعاب، الترفيه، وحتى المجالات الطبية.

15.2 البنية العامة للشبكات التوليدية الخصمية:(General Structure)

تتكون الشبكة من جزأين رئيسيين:

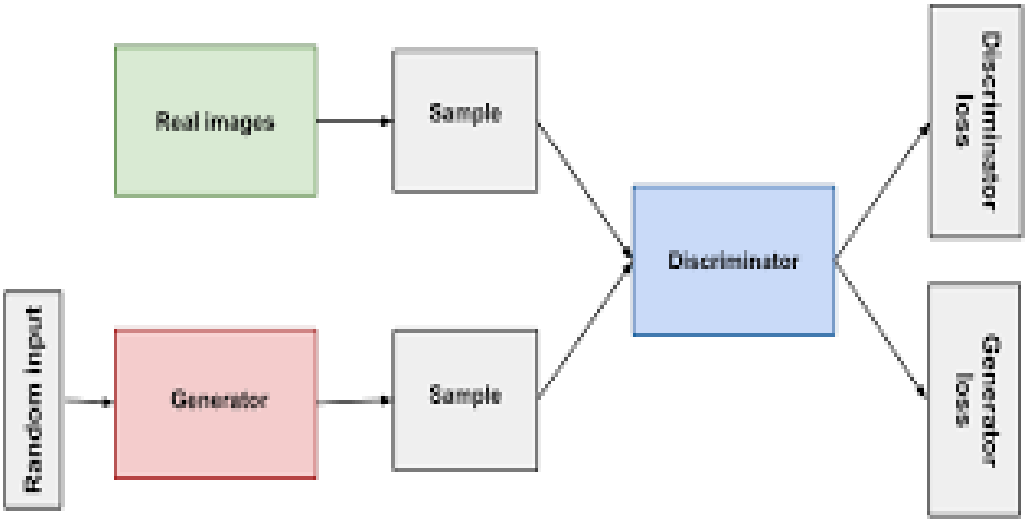
أ. المولّد:(Generator)
- هو شبكة عصبية عميقة تستقبل متجهًا عشوائيًا (Noise Vector) كمدخل.
- هذا الضجيج (عادةً موزع غاوسي أو منتظم) يتم تحويله عبر طبقات متعددة إلى صورة مزيفة.
- هدف المولّد :**خداع المميّز** بحيث يعتقد أن الصورة المولدة حقيقية.

ب. المميّز:(Discriminator)
- هو شبكة تصنيف ثنائية.(Binary Classifier)
- يتلقى صورًا سواء حقيقية من قاعدة البيانات أو مزيفة من المولّد.
- هدفه: التمييز بين الحقيقي والمزيف.

العلاقة التنافسية:
- المولّد يحاول تعظيم احتمالية خداع المميّز.
- المميّز يحاول تقليل احتمالية أن ينخدع.

- هذه العلاقة تخلق ما يُعرف بـ **اللعبة الصفرية.(Minimax Game)**

GANs Flow Chart 15.3



1. **إدخال الضجيج:(Input Noise)**
   يبدأ المولّد بمتجه ضجيج عشوائي.(Random Vector)
2. **المولّد ينتج صورة مزيفة:**
   الضجيج يمر عبر طبقات الشبكة العميقة ليُحوّل إلى صورة جديدة.
3. **المميّز يستقبل الصور:**
   - **صور حقيقية من قاعدة البيانات.**
   - **صور مزيفة من المولّد.**
4. **المميّز يصدر الحكم:**
   يعطي احتمالية لكل صورة: "حقيقية" أو "مزيفة."
5. **تحديث الأوزان:(Backpropagation)**
   - إذا نجح المميّز في كشف الصور، يُعاقب المولّد ويتعلم تحسين إنتاجه.
   - إذا فشل المميّز وانخدع، يتم تحسينه ليصبح أكثر صرامة.

6. **التكرار المستمر:**
مع مرور الزمن، يصبح المولّد بارعًا في توليد صور أقرب للحقيقة، والمميّز أكثر صعوبة في الانخداع، مما يرفع جودة النموذج بشكل متوازن.

تطبيقات عملية متقدمة لـ:GANs

- **Deepfakes:** إنتاج مقاطع فيديو وصور مزيفة بدقة مذهلة.
- **Image Inpainting:** إكمال الأجزاء الناقصة من الصور.
- **Super Resolution:** تحسين وضوح الصور القديمة أو منخفضة الجودة.
- **Style Transfer:** تحويل صورة لتتبع أسلوب فني معين (مثل لوحات فان غوخ).
- **الطب :** توليد صور أشعة اصطناعية للمساعدة في تدريب النماذج الطبية حيث البيانات الحقيقية نادرة.

---

16 توابع التفعيل - Non-linearity functions:

في الشبكات العصبية الاصطناعية، **توابع التفعيل (Activation Functions)** هي وظائف رياضية غير خطّية تُطبَّق على خرج كلّ عُقدة (Neuron) بعد عملية الجمع الخطي للمدخلات. أي أنّ كل خلية عصبية تستقبل مجموعة من القيم (مدخلات مضروبة بالأوزان ومضاف إليها الانحياز (*bias*، ثم تُمرَّر هذه القيمة عبر دالّة التفعيل لتحديد المخرجات.

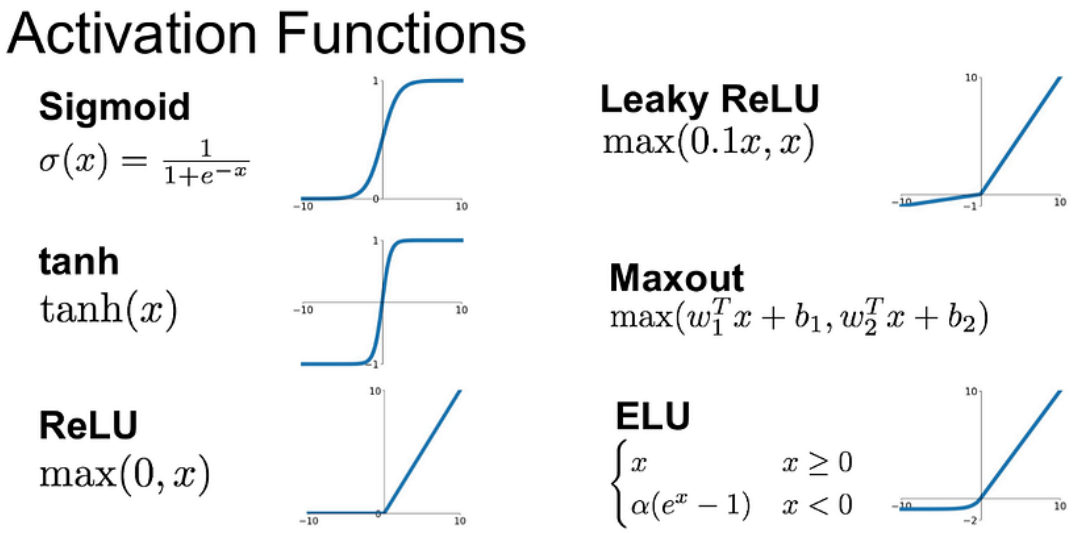
لماذا نستخدم دوال التفعيل؟

1. **إدخال اللاخطية (Non-linearity)**
لولا وجود دالّة التفعيل، ستكون الشبكة العصبية مجرد تركيب خطي (Linear Combination) مهما كبر عدد الطبقات، وبالتالي تصبح مكافئة لمعادلة خطية واحدة.
اللاخطية تجعل الشبكة قادرة على تمثيل العلاقات المعقدة والأنماط عالية التجريد.

2. **التحكم في نطاق القيم:**
بعض الدوال تحصر المخرجات في مدى محدد (مثل [0,1] أو[-1,1])، مما يسهل عملية التدريب ويُبقي القيم مستقرة.

3. **تيسير عملية التعلم العميق:**
بعض الدوال تساعد على تجنّب مشاكل مثل *Vanishing Gradient*أو *Exploding Gradient*، وبالتالي تُسرّع عملية الانتشار العكسي.(Backpropagation)

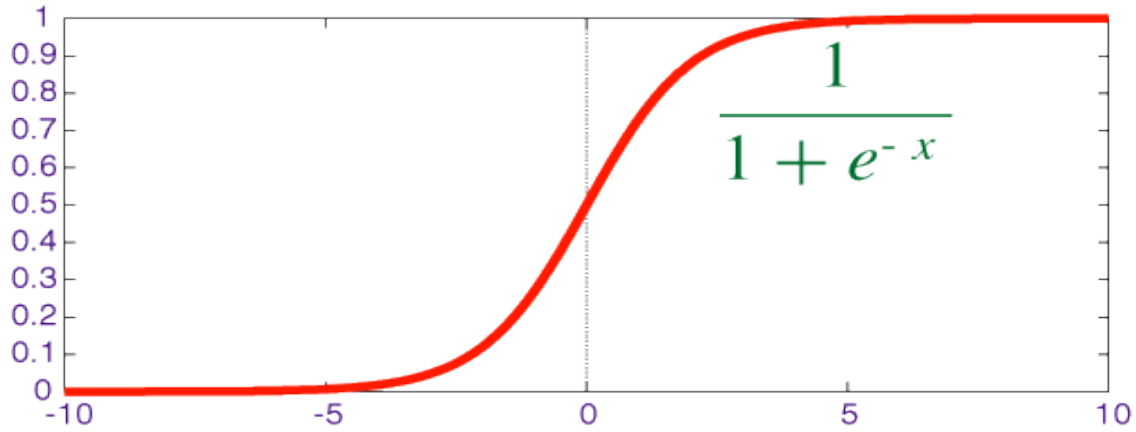
16.1 أشهر توابع التفعيل:



- **Sigmoid:**

تُحوّل القيم إلى مجال (0,1). كانت شائعة في الشبكات القديمة لكنها تعاني من بطء التعلم ومشكلة Vanishing Gradient

$$f(x) = \frac{1}{1+e^{-(x)}}$$



-يعد تابع ال Sigmoid من أشهر توابع التفعيل في المسائل المتعلقة بالتصنيف الثنائي

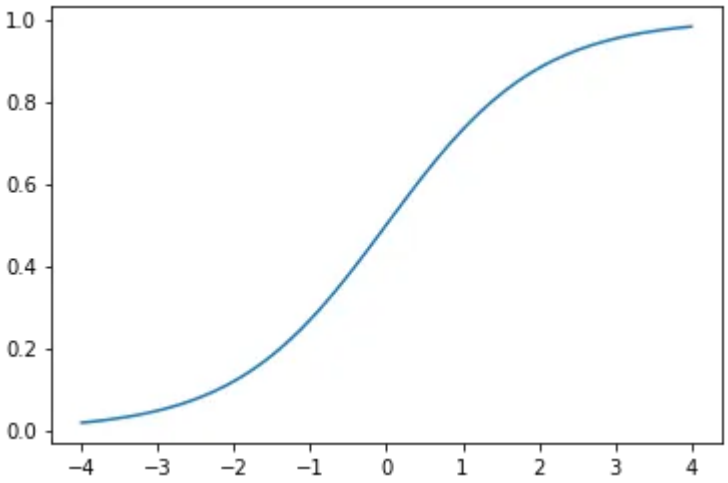
-يرجع تابع ال Sigmoid قيمة بين 0 و 1 وهذا يعد بغاية الأهمية في مسائل التصنيف

تفسير قيم تابع ال Sigmoid:

بفرض أننا قمنا بتدريب شبكة عصبية لتصنيف صور القطط والكلاب، وهي مشكلة كلاسيكية، حيث يمثل الكلب القيمة 1 والقط القيمة 0. ببساطة، عندما تُرجِع نموذجك قيمة ≤ 0.51، يعني ذلك أن الصورة لكلب، وعند قيمة > 0.51، يعني ذلك أن الصورة لقطة. **Tanh (Hyperbolic Tangent):**

شبيهة بالـ Sigmoid ولكن نطاقها [-1,1]، مما يجعلها متوازنة حول الصفر.

- **Softmax:**



غالبًا تُستخدم في طبقة الإخراج لمهام التصنيف، حيث تُحوّل القيم إلى احتمالات مجموعها يساوي 1.

- يستخدم في مجال أو فرع معالجات اللغات الطبيعية

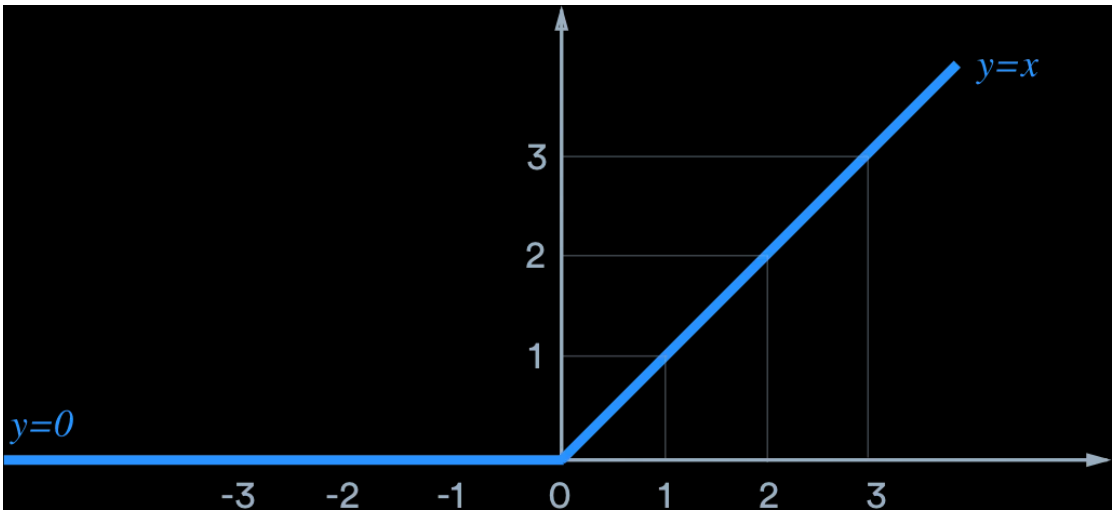
شكل التابع:

$$p(w(i) \mid C(w_n)) = \frac{\exp(y_i)}{\exp(y_1) + \exp(y_2) + \cdots + \exp(y_{V-1}) + 1}$$

- **ReLU (Rectified Linear Unit):**

تابع من توابع التفعيل اللاخطية يعرف رياضياً ب: y = max(0,x)

الرسم البياني:



يعد من أكثر التوابع الشائعة استخداماً في الشبكات العصبية عموماً وخصوصاً في شبكات الطي العصبونية .

أسباب الأستخدام:

عموما يستخدم كخيار أول عند عدم التأكد من التابع اللازم من أجل اللاخطية بالتدريب

يعد غير مكلف من الناحية الحسابية أي لا يحتوي على رياضيات صعبة أو معقدة

استخدامه يضمن عدم الوصول إلى مشكلة تلاشي الانحدار (vanishing gradient)

مشكلة – Dying ReLU :

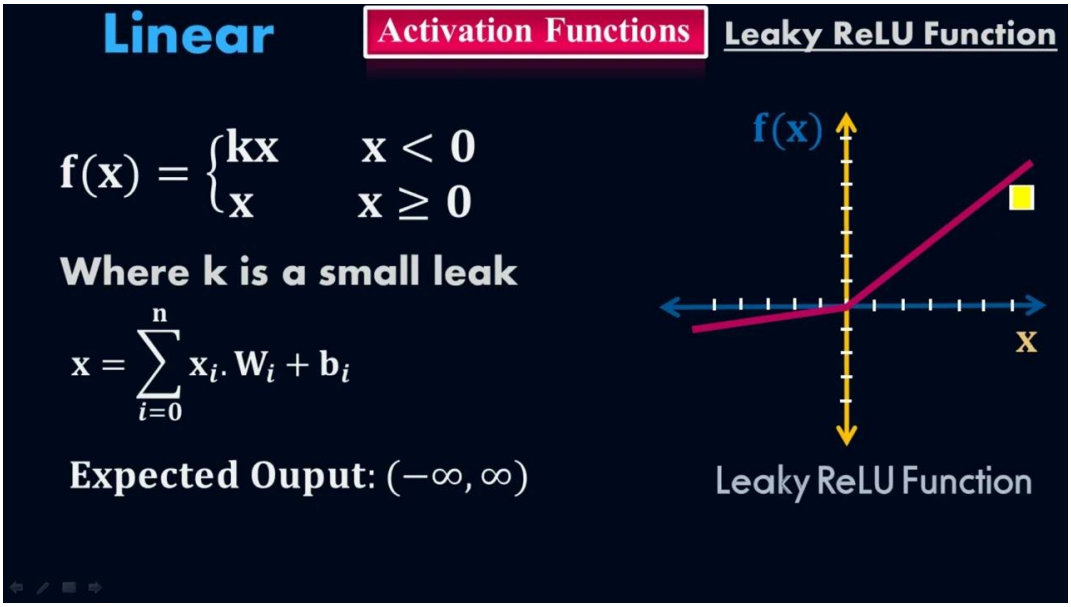
إن كونه يعطي القيمة صفر للقيم السالبة تعد أحد السلبيات لهذا التابع وتسمى بمشكلة Dying Relu كون العصبون يعطي قيم سالبة دائما فيصبح غير فعال بحالة دائمة أي لا يؤثر على الخرج أبدا وهي أيضاً بما يعرف بالعصبون الميت Dead Neuron

- **Leaky ReLU:**

إن دالّة Leaky ReLUهي تعديل على دالّة ReLU التقليدية. الفكرة الأساسية جاءت لمعالجة مشكلة

الوحدات الميتة فيReLU ؛ حيث قد تصبح بعض العُقد غير فعّالة كليًا إذا ظلّت تستقبل قيمًا سالبة.

الصيغة الرياضية:



حيث k ثابت صغير جدًا (مثل 0.01).

الخصائص:

- تسمح للقيم السالبة بالمرور بجزء صغير (بدل أن تُختزل إلى الصفر كليًا)، مما يُبقي على تدفّق المشتقات (gradients) ويُحافظ على حيوية الخلايا العصبية أثناء التعلم.
- تُحافظ على بساطة الحساب مثل ReLU.
- غالبًا تؤدي إلى أداء أفضل على بعض المهام مقارنة بـReLU ، خصوصًا عندما تكون البيانات معقدة وغير متماثلة.

---

17 خوارزمية التحسين "آدم(Adam Optimizer) "

خوارزمية **Adam**، اختصارًا لـ **Adaptive Moment Estimation**، هي خوارزمية تحسين من الدرجة الأولى تُستخدم على نطاق واسع في تدريب الشبكات العصبية العميقة. تم اقتراحها عام 2014 من قبل الباحثين Diederik P. Kingma و Jimmy Ba، وتُعد اليوم من أكثر خوارزميات التحسين استخدامًا في مجالات تعلم الآلة، نظرًا لقدرتها على التكيّف الديناميكي مع خصائص البيانات وتوفير استقرار في التدريب حتى في البيئات ذات الضوضاء العالية أو التدرجات المتفرقة.

17.1 المبدأ الرياضي وآلية العمل

تعتمد خوارزمية آدم على الجمع بين ميزات خوارزميتين سابقتين هما:

- **انحدار المشتق العشوائي مع الزخم (SGD with Momentum):** الذي يستخدم متوسطًا متحركًا للتدرجات لتسريع التقارب.
- **RMSProp:** الذي يضبط معدل التعلّم بناءً على متوسط مربع التدرجات.

آدم يقوم بتحديث أوزان النموذج باستخدام تقديرات لحظتين إحصائيتين:

- **اللحظة الأولى (m_t):** وهي المتوسط المتحرك للتدرجات (الزخم).
- **اللحظة الثانية (v_t):** وهي المتوسط المتحرك لمربعات التدرجات (التقلب).

يتم تصحيح هاتين اللحظتين لتقليل الانحياز الناتج عن التهيئة الصفرية، باستخدام معاملات تصحيح تُعرف باسم **bias-correction terms**.

معادلات التحديث الأساسية هي:

$$m_t = \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$$

$$v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$$

$$\hat{m}_t = m_t / (1 - \beta_1^t)$$

$$\hat{v}_t = v_t / (1 - \beta_2^t)$$

$$\theta_t = \theta_{t-1} - \alpha \cdot \hat{m}_t / (\sqrt{(\hat{v}_t)} + \varepsilon)$$

حيث:

- g_t): التدرج عند الزمن(t)
- θ_t): المعاملات (الأوزان) المراد تحسينها
- α): معدل التعلّم(Learning Rate)
- β_1, β_2): معاملات الزخم والتقلب (عادةً 0.9 و 0.999 على التوالي)
- ε): قيمة صغيرة لتجنب القسمة على صفر (عادةً 10^{-8})

الخصائص والمزايا

- **معدلات تعلّم تكيّفية** لكل معامل على حدة، مما يُحسّن من كفاءة التدريب.

- **تصحيح الانحياز** الناتج عن التهيئة، مما يُعزز من دقة التحديثات في المراحل الأولى من التدريب.
- **استهلاك منخفض للذاكرة** مقارنةً بخوارزميات أخرى مثل.AdaGrad
- **استقرار في التدريب** حتى في حالات الضوضاء العالية أو البيانات غير المتوازنة.
- **سهولة الضبط** :لا تتطلب الخوارزمية ضبطًا دقيقًا للمعاملات، وتعمل بكفاءة في معظم الحالات باستخدام القيم الافتراضية.

التطبيقات العملية

تُستخدم خوارزمية آدم في مجموعة واسعة من التطبيقات، منها:

- تصنيف الصور باستخدام الشبكات الالتفافية(CNN)
- تحليل النصوص باستخدام الشبكات التكرارية (RNN) أو المحولات(Transformers)
- توليد الصور والنصوص باستخدام الشبكات التوليدية(GANs)
- تحسين نماذج التعلم العميق في البيئات ذات البيانات الضخمة أو المتفرقة

التحديات والقيود

رغم شعبيتها، إلا أن بعض الدراسات الحديثة أشارت إلى أن آدم قد لا يُحقق دائمًا أفضل تعميم (Generalization)مقارنةً بخوارزميات مثل SGD في بعض المهام، خصوصًا في تصنيف الصور على مجموعات بيانات مثل .CIFAR لذلك، يُوصى أحيانًا باستخدام آدم في المراحل الأولى من التدريب، ثم التحول إلى خوارزميات أخرى لضبط النموذج النهائي.

18 لغة Python:

هي لغة برمجة عالية المستوى سهلة التعلم مفتوحة المصدر، تعتمد أسلوب البرمجة الكائنية (OOP) لغة بايثون هي لغة مفسرة، ومتعددة الاستخدامات، وتستخدم بشكل واسع في العديد من المجالات كبناء البرامج المستقلة باستخدام الواجهات الرسومية وفي تطبيقات الويب.

- مميزات البايثون :

تدعم برمجة التطبيقات المعتمدة على الذكاء الاصطناعي والتعلم العميق لاحتوائها على العديد من المكتبات التي تساعد في تحقيق الهدف البرمجي بأقل تعقيد ممكن من حيث الوقت المستهلك. بالمعالجة وكذلك الحجرات المحجوزة بالذاكرة.
لغة برمجية عالية المستوى
عندما تكتب البرامج في بايثون، لا داعي للاهتمام بالتفاصيل دقيقة المستوى مثل إدارة الذاكرة التي

يستخدمها برنامجك فبايثون تستخدم نظام برمجي ديناميكي لإدارة الذاكرة.

- Cross Platform

نظراً لطبيعتها البرمجية مفتوحة المصدر، فهي تعمل في العديد من المنصات. كل ما يكتب من برامج بايثون يمكن أن يعمل على أي من هذه المنصات دون أن يتطلب ذلك أي تغييرات على الإطلاق.

19 بعض المكاتب الشهيرة

NumPy

- **الوصف :**مكتبة الحوسبة الرقمية الأكثر شهرة في Python.
- **الاستخدام مع TensorFlow:** تُستخدم لعمليات المصفوفات، والمعالجات الرياضية الأساسية (Matrix Multiplication, Broadcasting)، وغالباً ما تكون البنية الأساسية لتجهيز البيانات (Preprocessing)قبل تمريرها إلى نموذج TensorFlow.
- **ملحوظة** TensorFlow :يدعم الآن كائنات Tensors متوافقة مع NumPy مما يجعل التداخل بينهما سلسًا.

Pandas

- **الوصف :**مكتبة متخصصة في معالجة وتحليل البيانات الجدولية.(Tabular Data)
- **الاستخدام مع TensorFlow:** تُستخدم في قراءة، تنظيف، وتجهيز مجموعات البيانات (CSV, Excel, SQL)خاصة في مشاريع التصنيف أو الانحدار التي تعتمد على بيانات منظمة.

Matplotlib

- **الوصف :**مكتبة رسم بياني (Visualization) لعرض وتحليل البيانات بصرياً.
- **الاستخدام مع TensorFlow:** تُستخدم لرسم منحنيات التعلم(Loss, Accuracy) ، وتحليل بيانات الصور(Image Visualization) ، وكذلك لفحص نتائج النموذج.(Confusion Matrix)

Seaborn

- **الوصف :**مكتبة متقدمة للرسم البياني تعتمد على Matplotlib لكنها تُقدم واجهة مرئية جميلة وسهلة.
- **الاستخدام مع TensorFlow:** تُستخدم في تحليل البيانات الاستكشافي (EDA) قبل تدريب النموذج، وكذلك في عرض العلاقات الإحصائية بين الخصائص.(Features)

OpenCV (cv2)

- **الوصف :**مكتبة متقدمة لمعالجة الصور والرؤية الحاسوبية.
- **الاستخدام مع TensorFlow:** تُستخدم في معالجة الصور (Image Augmentation, Resizing, Filtering)قبل تمريرها إلى الشبكات العصبية، خاصة في تطبيقات تصنيف الصور أو الكشف عن الكائنات.

Scikit-learn

- **الوصف:** مكتبة شهيرة لتطبيق خوارزميات تعلم الآلة الكلاسيكية.
- **الاستخدام مع TensorFlow:** تُستخدم في تقسيم البيانات (Train/Test Split), تنفيذ تقنيات تقليدية (PCA, SVM)، وأيضاً لحساب مقاييس التقييم.(Accuracy, F1-score, Confusion Matrix)

TensorFlow Hub

- **الوصف:** مكتبة رسمية من Google لتحميل واستخدام النماذج المدربة مسبقاً (Pre-trained Models).
- **الاستخدام:** تمكنك من استخدام نماذج جاهزة مثل EfficientNet, BERT, MobileNet بسهولة داخل مشاريعك.

TensorFlow Datasets (tfds)

- **الوصف:** مكتبة توفر مجموعات بيانات قياسية (MNIST, CIFAR-10, COCO) بشكل مهيأ وجاهز للاستخدام.
- **الاستخدام:** تُستخدم في تحميل مجموعات البيانات الشهيرة بأوامر بسيطة وتجهيزها للتدريب بدون الحاجة لتحميلها يدوياً.

Keras (TensorFlow)

- **الوصف:** واجهة برمجية عالية المستوى لبناء نماذج التعلم العميق.
- **الاستخدام:** تُستخدم في بناء وتدريب النماذج العصبية باستخدام واجهات برمجية بسيطة وقوية، وهي الآن مدمجة بالكامل في TensorFlow 2.x.

Albumentations

- **الوصف:** مكتبة قوية ومتقدمة لتقنيات زيادة البيانات (Data Augmentation) خاصة في الصور.
- **الاستخدام مع TensorFlow:** تُستخدم في تطبيق تحولات معقدة (Rotations, Cutouts, Distortions)لزيادة التنوع في البيانات التدريبية.

TensorBoard

- **الوصف:** أداة رسم بياني رسمية من TensorFlow.
- **الاستخدام:** تُستخدم لمراقبة أداء النماذج أثناء التدريب (Loss, Accuracy, Weights Histograms)من خلال واجهة رسومية تفاعلية عبر المتصفح.

H5py

- **الوصف:** مكتبة للتعامل مع ملفات HDF5.
- **الاستخدام مع TensorFlow:** تُستخدم لحفظ النماذج المدربة (Model Checkpoints) والبيانات الثقيلة (Large Datasets) بصيغ HDF5، خاصة في المشاريع التي تتطلب حفظ النماذج بأمان.

Plotly

- **الوصف:** مكتبة رسم بياني تفاعلية متقدمة.
- **الاستخدام مع TensorFlow:** تُستخدم في بناء مخططات تفاعلية (3D Plots, Interactive Confusion Matrix)، تساعد في تقديم عروض مرئية غنية لنتائج النماذج.

TF-Addons (TensorFlow Addons)

- **الوصف:** مكتبة من Google تحتوي على إضافات متقدمة (Custom Loss Functions, Metrics, Layers) غير متوفرة في النواة الأساسية لـ TensorFlow.
- **الاستخدام:** تُستخدم في المشاريع التي تتطلب وظائف مخصصة متقدمة غير موجودة في TensorFlow الافتراضي.

ONNX (Open Neural Network Exchange)

- **الوصف:** مكتبة مفتوحة المصدر لتحويل النماذج بين PyTorch, TensorFlow، وأطر أخرى.
- **الاستخدام مع TensorFlow:** تُستخدم في تحويل النماذج من PyTorch إلى TensorFlow أو العكس، خاصة في سيناريوهات تحتاج إلى توافق عبر بيئات متعددة.

كيف تتكامل هذه المكتبات مع سير العمل في TensorFlow؟

1. **تحليل البيانات الأولي (EDA):** باستخدام Pandas, NumPy, Seaborn, Matplotlib.
2. **معالجة البيانات وتحضيرها:** OpenCV, Albumentations, Scikit-learn.
3. **تحميل النماذج والبيانات:** TensorFlow Hub, TensorFlow Datasets.
4. **بناء النماذج:** TensorFlow + Keras + TensorFlow Addons.
5. **مراقبة الأداء وتحليل النتائج:** TensorBoard, Plotly, Scikit-learn metrics.
6. **حفظ وتصدير النماذج:** H5py, ONNX.
7. **النشر والإنتاج:** TensorFlow Lite, TensorFlow Serving (خارج سياق المكتبات البرمجية لكنها جزء من البيئات المدعومة).

20 إطار العمل – TensorFlow

TensorFlowهو إطار عمل مفتوح المصدر للتعلّم الآلي والتعلّم العميق، طوّرته **Google Brain**. يعتمد على **الرسم البياني الحسابي (Computational Graph)** لتمثيل العمليات الرياضية وتدفق البيانات (Tensors) بين هذه العمليات.

يُستخدم على نطاق واسع في البحث الأكاديمي والصناعة لبناء وتدريب ونشر نماذج الذكاء الاصطناعي، خاصة الشبكات العصبية العميقة.

يدعم العمل على **وحدات المعالجة المركزية (CPU)** و**وحدات معالجة الرسوميات (GPU)** وحتى **وحدات المعالجة المخصصةTPU** ، ويمكن تشغيله على الحواسيب المكتبية، الخوادم، والأجهزة المحمولة.

يتميز Tensorflow بالتالي:

- **مرونة عالية** :يدعم كلًا من التنفيذ الفوري (Eager Execution) والتنفيذ البياني (Graph Execution).
- **تكامل مع Keras**: واجهة برمجة عالية المستوى تسهّل بناء النماذج بسرعة.
- **قابلية التوسع** :يمكن تشغيله على جهاز واحد أو على مئات الأجهزة في بيئة موزعة.
- **دعم متعدد المنصات** :يعمل على أنظمةWindows ، Linux، macOS، Android، و iOS.
- **نظام بيئي متكامل** :يشمل أدوات مثل :
  - **TensorBoard**:لتصور البيانات ومراقبة التدريب.
  - **TensorFlow Lite**:للنشر على الأجهزة المحمولة.
  - **TensorFlow Extended (TFX)**:لإدارة خطوط إنتاج التعلم الآلي.
- **مجتمع ضخم ودعم مستمر** :موارد تعليمية، مكتبات إضافية، وأمثلة جاهزة.

نقاط القوة

1. **أداء عالٍ** بفضل دعم المعالجات الرسومية وTPU.
2. **تنوع التطبيقات** :رؤية حاسوبية، معالجة لغة طبيعية، تحليل بيانات، وغيرها.
3. **دعم التوزيع** :تدريب النماذج على عدة أجهزة أو عقد حوسبة.
4. **تكامل مع لغات وأدوات أخرى**Python :، C++، Java، وواجهات برمجة متعددة.
5. **إمكانية النشر بسهولة** على السحابة أو الأجهزة الطرفية.

المساوئ

- **منحنى تعلم مرتفع** :خاصة عند العمل بالمستوى المنخفض (Low-level API) أو الرسوم البيانية المعقدة.

- **حجم الإطار كبير** :مقارنة ببعض المكتبات الأخف مثل PyTorch أو Scikit-learn.
- **التصحيح (Debugging)** في وضع الرسم البياني أصعب من التنفيذ الفوري.
- **تغييرات الإصدارات** :بعض التحديثات الكبيرة تغيّر واجهات البرمجة، مما قد يتطلب تعديل الكود.

21 قاعدة البيانات

معنى قاعدة البيانات

قاعدة البيانات هي مجموعة مرتبة من البيانات، وتشير إلى المعلومات التي تم الحصول عليها من خلال الملاحظات أو القياسات أو الدراسة أو التحليل. يمكن أن تشمل حقائق، أرقام، أشكال، أسماء، أو أوصاف للأشياء. تُنظم البيانات في رسوم بيانية، مخططات، أو جداول، ويُستخدم التنقيب في البيانات لتحليلها.

21.1 أنواع مجموعات البيانات

في الإحصاء، توجد أنواع متعددة من مجموعات البيانات:

- العددية :(Numerical) بيانات رقمية قابلة للحساب مثل الوزن والطول.
- ثنائية المتغير :(Bivariate) تحتوي على متغيرين مترابطين مثل مبيعات الآيس كريم ودرجة الحرارة.
- متعددة المتغيرات :(Multivariate) تحتوي على ثلاثة أو أكثر من المتغيرات مثل قياسات الصندوق.
- الفئوية :(Categorical) تمثل خصائص مثل الجنس أو الحالة الاجتماعية.
- الارتباط :(Correlation) تظهر العلاقة بين القيم، مثل العلاقة بين الطول والوزن.

21.2 مجموعات البيانات المستخدمة – UTKFace DataSet:

- **وصف قاعدة بيانات:**

UTKFace: قاعدة بيانات **UTKFace** هي مجموعة بيانات ضخمة ومفتوحة المصدر تُستخدم على نطاق واسع في مجالات تعلم الآلة ورؤية الحاسوب، وتركّز بشكل خاص على تحليل الوجوه البشرية. تم تطويرها بهدف دعم الأبحاث المتعلقة بتقدير العمر، تصنيف الجنس، والتعرف على العِرق من خلال صور الوجه، وتُعد من أكثر قواعد البيانات شمولًا وتنوعًا في هذا المجال.

- **مكونات قاعدة البيانات:**

- تحتوي على أكثر من **23,000صورة وجه** لأفراد من أعمار مختلفة تتراوح بين **0إلى 116 عامًا**، مما يجعلها مناسبة لدراسات تمتد عبر مراحل الحياة المختلفة.
- كل صورة تم اقتصاصها وتعديلها لتُظهر وجهًا واحدًا فقط، مما يسهل عمليات المعالجة والتعلم الآلي.

- الصور مأخوذة من بيئات متنوعة"in-the-wild" ، أي أنها ليست ملتقطة في ظروف معملية، بل تم جمعها من الإنترنت، مما يضفي واقعية وتنوعًا كبيرًا على البيانات.

- **البيانات المصنفة(Annotations)**

كل صورة في قاعدة البيانات تحمل معلومات مشفّرة ضمن اسم الملف، تشمل:

- **العمر** :رقم صحيح بين 0 و116.
- **الجنس** 0 :للذكور، 1 للإناث.
- **العِرق** :رقم من 0 إلى 4، حيث يُمثل :
  - **0 أبيض**
  - **1 أسود**
  - **2 آسيوي**
  - **3 هندي**
  - **4 أعراق أخرى (مثل لاتيني، شرق أوسطي، إلخ)**

- **تاريخ ووقت الالتقاط**:بصيغة زمنية دقيقة (yyyyMMddHHmmssSSS)

- **الخصائص التقنية**

- الصور تم تعديلها باستخدام مكتبة **Dlib** لتكون **محاذاة ومقصوصة** بشكل موحد، مما يسمح بتحليل أكثر دقة.
- تتوفر أيضًا **معالم الوجه (landmarks)** مكونة من 68 نقطة لكل صورة، وهي مفيدة لتطبيقات مثل تتبع تعابير الوجه أو محاكاة التقدم في العمر.
- الصور تتنوع في :
  - **زاوية الالتقاط(pose)**
  - **الإضاءة(illumination)**
  - **التعبير(expression)**
  - **وجود عناصر حجب(occlusion)**
  - **الدقة(resolution)**

- **الاستخدامات البحثية**

قاعدة بيانات UTKFace تُستخدم في مجموعة واسعة من التطبيقات البحثية، منها:

- تقدير العمر باستخدام الشبكات العصبية العميقة
- تصنيف الجنس والعِرق
- تحليل التغيرات العمرية(Age Progression/Regression)
- التعرف على الوجه
- استخراج معالم الوجه وتحديد النقاط الحيوية
- تدريب نماذج التعلم العميق على بيانات غير متوازنة ومتنوعة

- **الاعتبارات القانونية والأخلاقية**

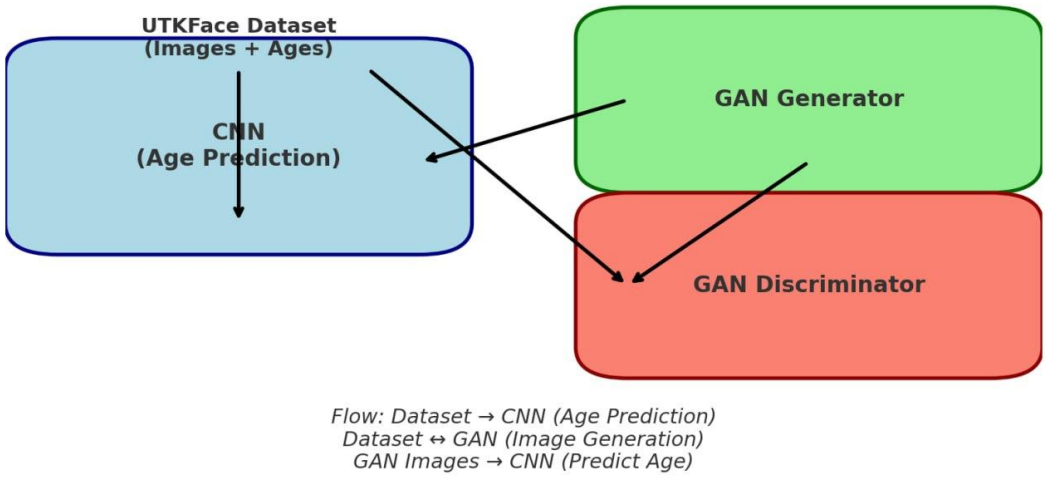
- قاعدة البيانات متاحة فقط لأغراض **البحث غير التجاري**.
- الصور تم جمعها من الإنترنت، ولا تعود ملكيتها لمطوري قاعدة البيانات، بل لأصحابها الأصليين.
- تم التحقق من صحة التصنيفات باستخدام خوارزميةDEX ، ثم مراجعتها يدويًا لضمان الدقة.

22 التطبيق العملي:

- تم تطوير نموذج ذكاء اصطناعي هجين يجمع بين الشبكات العصبية الالتفافية (CNN) والشبكات التوليدية الخصومية (GAN).

- بهدف تحسين قدرة النموذج على التعميم ومواجهة البيانات ذات التحديات البصرية.

- تعتمد البنية المقترحة على استخدام الجزء التوليدي في الـGAN لإنتاج عينات إضافية من البيانات التدريبية تتضمن ضوضاء اصطناعية، مثل النقاط البيضاء العشوائية، لمحاكاة ظروف تصوير غير مثالية وزيادة تنوع مجموعة البيانات. يتيح هذا النهج للنموذج القائم على الـCNN التعرض لسيناريوهات أكثر تعقيدًا أثناء التدريب، مما يعزز مناعته ضد التشويش ويحسن دقته في التعرف على الأنماط في بيئات واقعية ذات جودة



الشكل: 22 - 1 النموذج المختار

22.1 النسخة الأولى – Version 1 :

- إعدادات التدريب CNN
  - عدد الحُقب 10 = (**Epochs**)
  - نسبة التحقق 0.1 = (**Validation Split**)
  - حجم الدُفعة 32 = (**Batch Size**)

- النتائج :
  - **Loss** = 62.6
  - **MAE = 4.25**

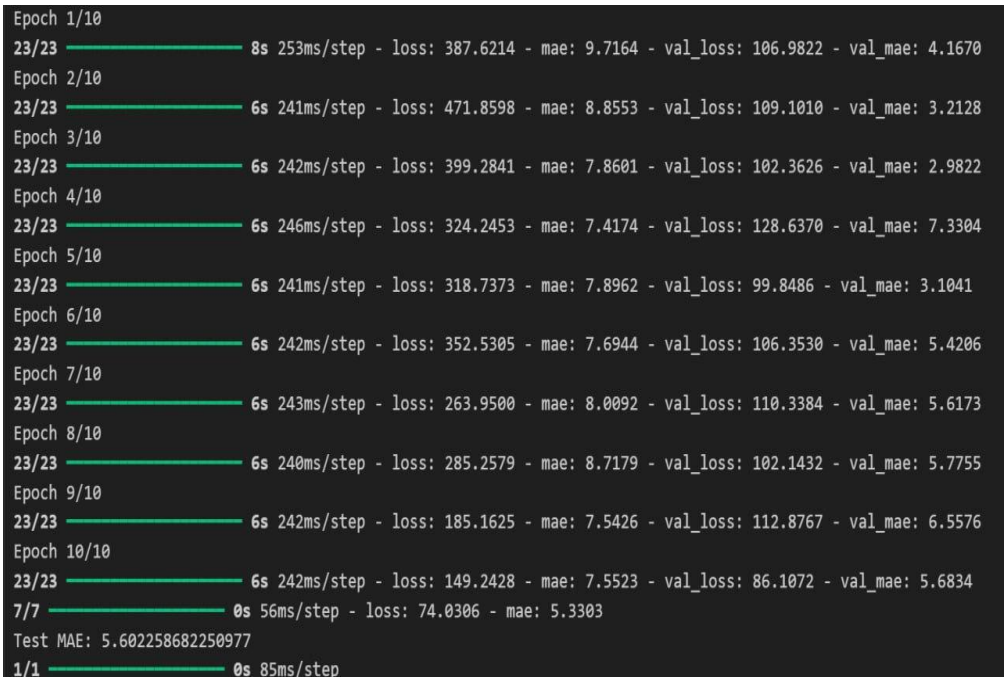
- **المُولّد :(Generator)** يتكون من **4طبقات**، ويُستخدم لتوليد تمثيلات جديدة أو محسّنة للوجه.
- **المُميّز :(Discriminator)** يتكون من **3طبقات**، منها طبقة كثيفة (**Dense Layer**) تُستخدم لتقييم جودة التمثيلات المُولّدة.

- تم استخدام تقنية **Dropout = 0.3** لتقليل فرط التكيف وتحسين التعميم.
- إعدادات التدريب :

- عدد الحُقب = 5 (**Epochs**)
- حجم الدُفعة = 32 (**Batch Size**)

- النتائج :
  - **Loss** = 74.03
  - **MAE** = 5.33

22.1.1 خرج الشبكة الالتفافية بالنسخة الأولى – CNN OUTPUT for each Epoch



22.1.2 خرج الشبكة التنافسية بالنسخة الأولى – GAN OUTPUT For Each Epoch

Epoch 1/5 - D loss real: 0.7213, D loss fake: 0.7223, G loss: 0.6499

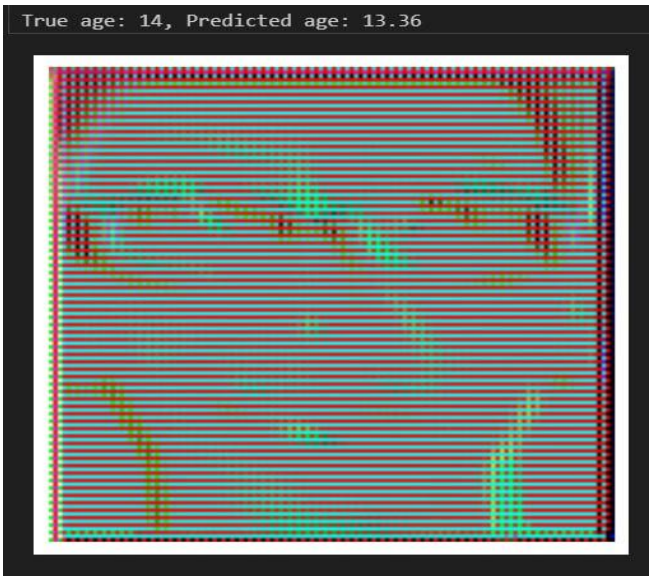
Epoch 2/5 - D loss real: 0.7315, D loss fake: 0.7323, G loss: 0.6297

Epoch 3/5 - D loss real: 0.7386, D loss fake: 0.7391, G loss: 0.6166

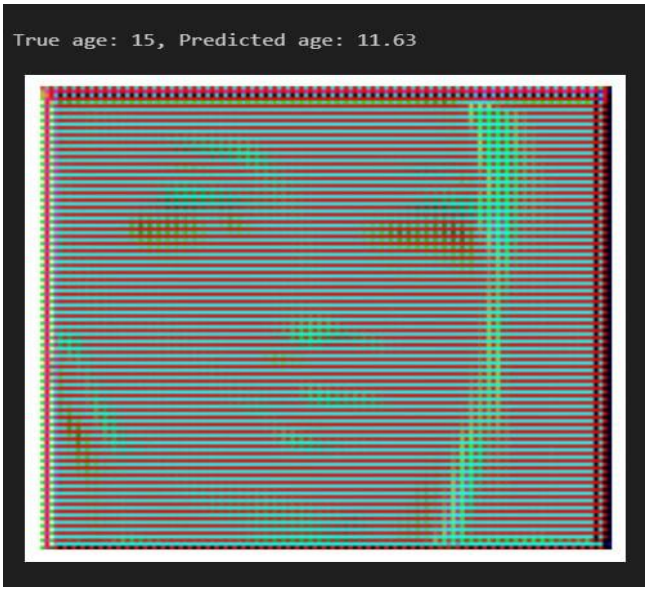
Epoch 4/5 - D loss real: 0.7451, D loss fake: 0.7455, G loss: 0.6061

Epoch 5/5 - D loss real: 0.7512, D loss fake: 0.7517, G loss: 0.5963

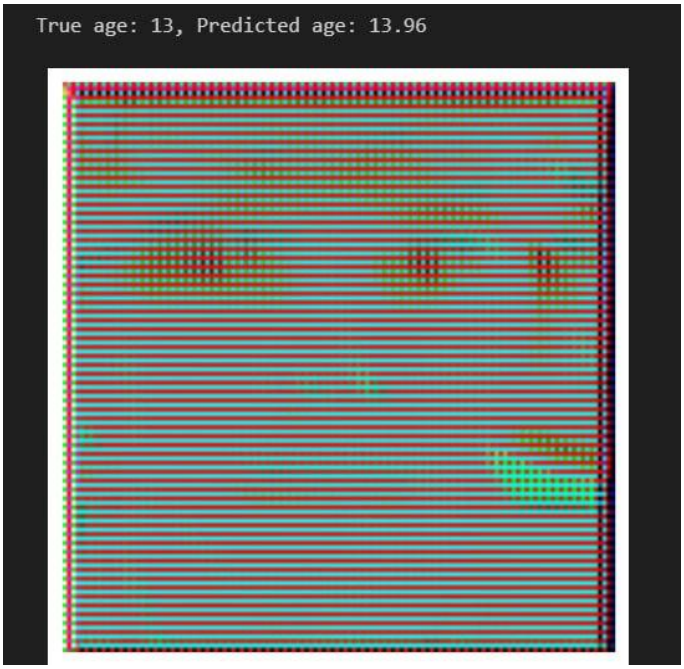
22.1.3 نتائج النسخة الأولى



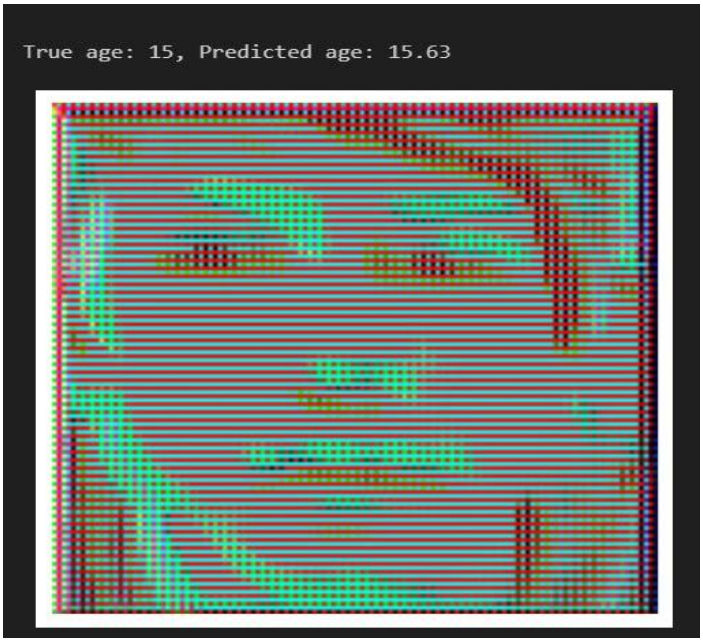
نلاحظ ظهور طفيف لملامح العيون والفم، مع بروز خطوط أفقية ملوّنة تؤثر على وضوح التفاصيل الدقيقة



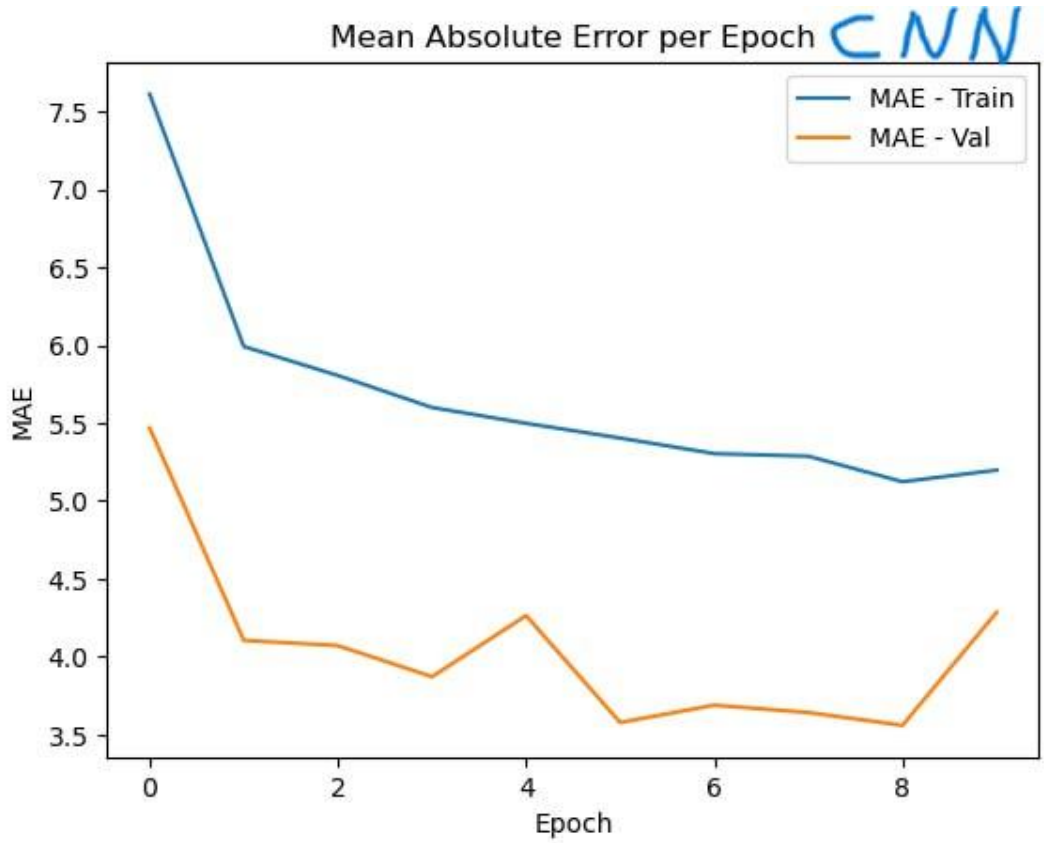
- **نلاحظ أن ملامح الوجه، خاصة العينين والفم، أقل وضوحًا مقارنة بالصور الأخرى، مع سيطرة التشويش اللوني على معظم التفاصيل.**



- **نلاحظ وضوح نسبي لملامح الوجه الأساسية، خاصة شكل العينين والفك، رغم التشويش اللوني الأفقي.**



- **نلاحظ بروز جيد لملامح العينين والفم، مع قدرة واضحة على التقاط شكل الوجه العام رغم التشويش.**



الشكل 19 - 1 1 MAE CNN IN Version

- **الخط الأزرق (MAE - Train): يوضح خطأ النموذج على بيانات التدريب. نلاحظ أنه ينخفض تدريجيًا مع الحِقَب، مما يعني أن النموذج يتعلم ويصبح أكثر دقة على بياناته.**
- **الخط البرتقالي (MAE - Val): يوضح خطأ النموذج على بيانات التحقق (Validation). نلاحظ أنه يتذبذب قليلًا لكنه عمومًا أقل من خطأ التدريب في معظم الحِقَب**

الخلاصة:

نلاحظ افتقاد النموذج إلى عدة أمور منها:

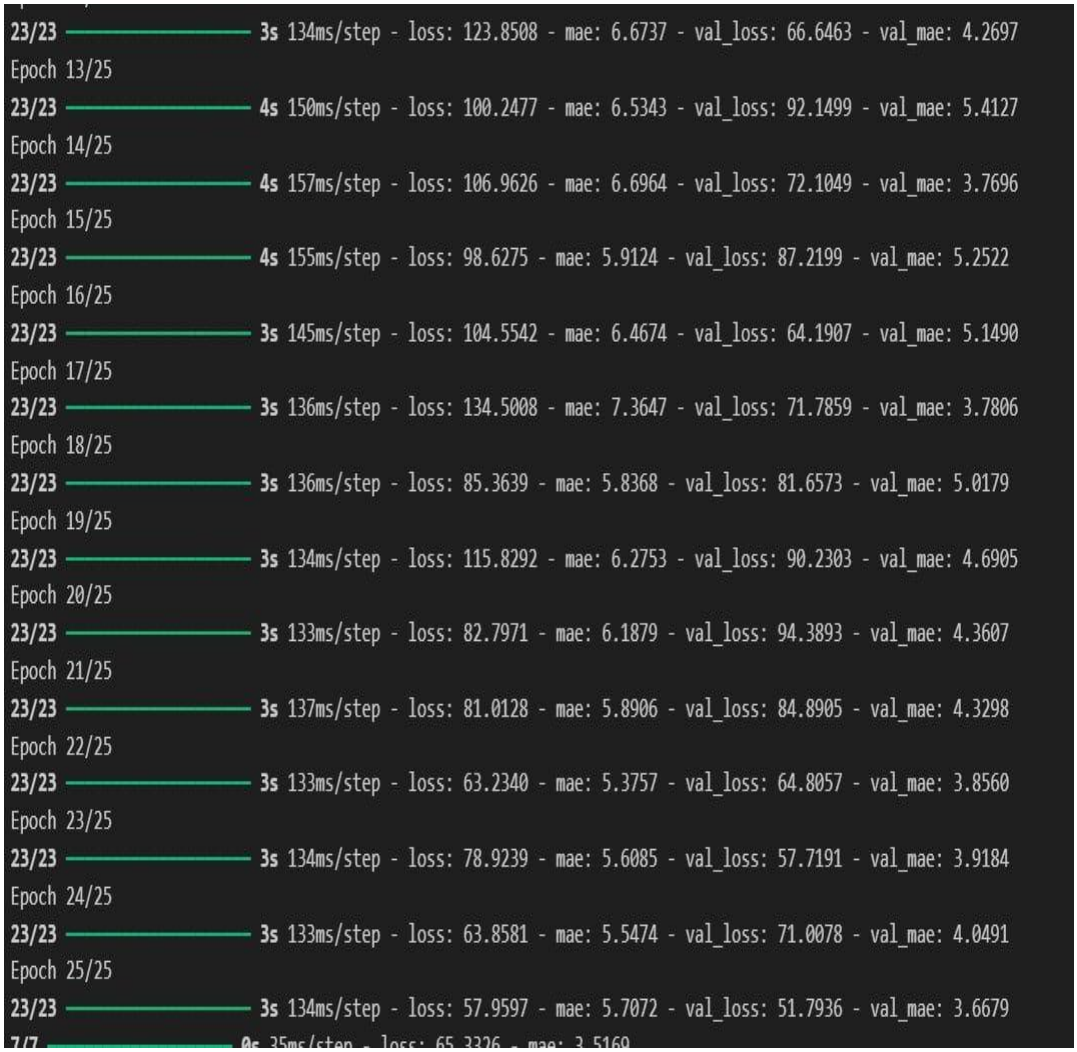
- **معالجة أفضل لتأثير الألوان المتداخلة، مما قد يسبب انحرافًا بسيطًا نحو تقدير عمر أكبر.**
- **تمييز أفضل لملامح البشرة الدقيقة، ما قد يؤدي إلى زيادة طفيفة في التقدير عن العمر الحقيقي**
- **القدرة على استخلاص السمات العمرية الدقيقة، مما أدى إلى تقدير أقل بكثير من العمر الحقيقي.**
- **القدرة على استخلاص السمات العمرية الدقيقة، مما أدى إلى تقدير أقل بكثير من العمر الحقيقي.**

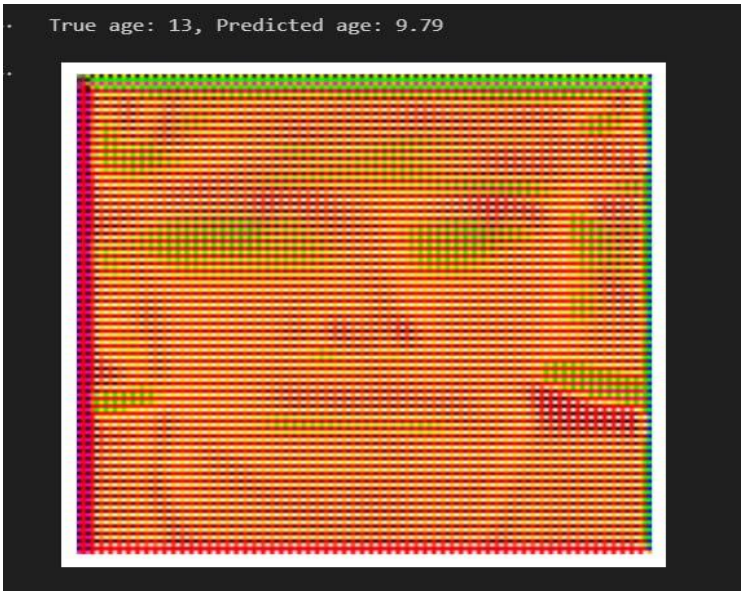
22.2 النسخة الثانية:

22.2.1 خرج الشبكة التنافسية بالنسخة الثانية – GAN OUTPUT For Each Epoch

Epoch 5/5 - D loss real: 0.7331, D loss fake: 0.7334, G loss: 0.6209

22.2.2 خرج الشبكة الالتفافية بالنسخة الثانية – CNN OUTPUT for each Epoch





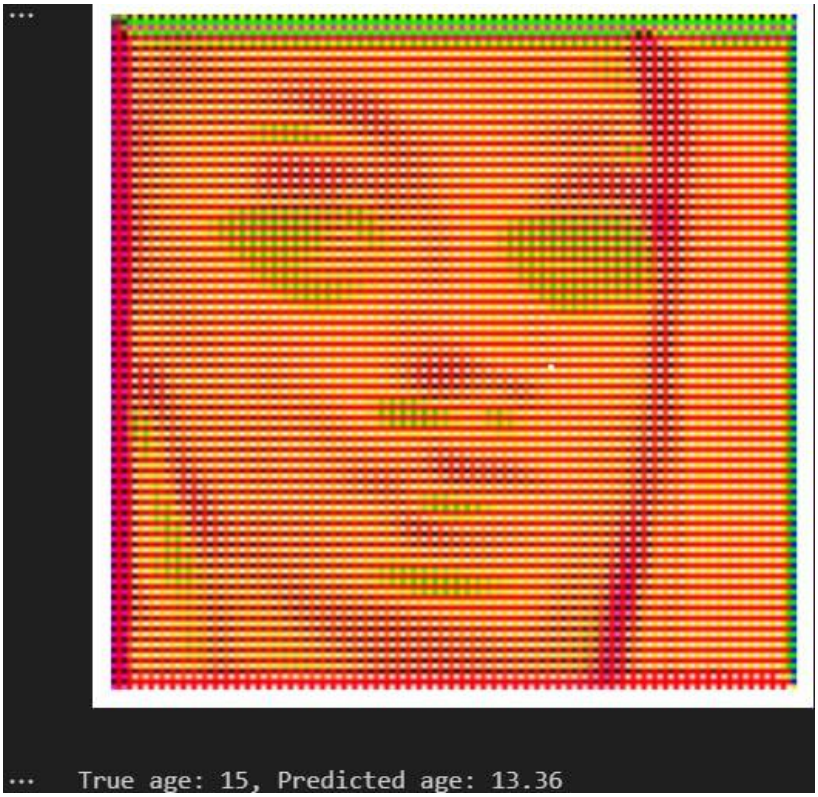
- **نلاحظ وضوح ملامح العينين والفم بشكل متوسط، مع بروز ألوان حرارية (أحمر/أصفر/أخضر) على شكل مربعات صغيرة، مما يشير إلى تمثيل شبكي/شبكة مخرجات النموذج**



- **ملامح الوجه واضحة نسبيًا، مع توزيع ألوان حرارية على شكل نقاط أفقية، لكن التشويش اللوني يضعف وضوح النسيج الجلدي.**



- **نلاحظ وضوح ملامح العينين والفم بشكل متوسط، مع بروز ألوان حرارية (أحمر/أصفر/أخضر) على شكل مربعات صغيرة، مما يشير إلى تمثيل شبكي/شبكة مخرجات النموذج**



- **نلاحظ ظهور ملامح الوجه الأساسية مع خطوط أفقية من نقاط ملوّنة، لكن التفاصيل الدقيقة حول العينين والفم أقل وضوحًا.**

الخلاصة:

- **مازالت الدقة المطلوبة والتعرف على ملامح الوجه والسمات العمرية يحتاج الى تدريب اكثر دقة من الأمور التي يفتقرها هذا النموذج هي :**

- **يفتقد النموذج إلى التقاط السمات العمرية الدقيقة، خصوصًا في منطقة العينين والفم، مما أدى إلى تقدير أقل بكثير من العمر الحقيقي (حوالي -3 سنوات).**
- **يفتقد النموذج إلى معالجة فعّالة للتشويش الأفقي، مما يقلل من دقة التقدير ويؤدي إلى انحراف سلبي في العمر المتوقع.**

22.3 النسخة الثالثة للتدريب – V3 :

22.3.1 خرج الشبكة التنافسية بالنسخة الثالثة – GAN OUTPUT For Each Epoch

GAN Epoch 1/30 - Gen Loss: 1.0732, Disc Loss: 0.9457

GAN Epoch 2/30 - Gen Loss: 0.6874, Disc Loss: 1.4326

GAN Epoch 3/30 - Gen Loss: 0.7444, Disc Loss: 1.3814

GAN Epoch 4/30 - Gen Loss: 0.6613, Disc Loss: 1.4198

GAN Epoch 5/30 - Gen Loss: 0.7618, Disc Loss: 1.2818

GAN Epoch 6/30 - Gen Loss: 1.0990, Disc Loss: 0.9701

GAN Epoch 7/30 - Gen Loss: 0.8105, Disc Loss: 1.3314

GAN Epoch 8/30 - Gen Loss: 1.2258, Disc Loss: 1.0824

GAN Epoch 9/30 - Gen Loss: 2.1527, Disc Loss: 1.7388

GAN Epoch 10/30 - Gen Loss: 1.0669, Disc Loss: 0.7958

GAN Epoch 11/30 - Gen Loss: 1.1658, Disc Loss: 1.2011

GAN Epoch 12/30 - Gen Loss: 0.8810, Disc Loss: 1.8206

GAN Epoch 13/30 - Gen Loss: 0.7476, Disc Loss: 1.0662

GAN Epoch 14/30 - Gen Loss: 0.8684, Disc Loss: 1.2497

GAN Epoch 15/30 - Gen Loss: 1.0132, Disc Loss: 1.0839

GAN Epoch 16/30 - Gen Loss: 2.0207, Disc Loss: 1.0672

GAN Epoch 17/30 - Gen Loss: 1.0496, Disc Loss: 0.9133

GAN Epoch 18/30 - Gen Loss: 1.1379, Disc Loss: 1.2035

GAN Epoch 19/30 - Gen Loss: 0.8337, Disc Loss: 1.9083

GAN Epoch 20/30 - Gen Loss: 0.5020, Disc Loss: 2.4132

GAN Epoch 21/30 - Gen Loss: 0.6309, Disc Loss: 1.3432

GAN Epoch 22/30 - Gen Loss: 0.4473, Disc Loss: 2.1229

GAN Epoch 23/30 - Gen Loss: 0.6177, Disc Loss: 1.3474

GAN Epoch 24/30 - Gen Loss: 1.1087, Disc Loss: 1.2590

GAN Epoch 25/30 - Gen Loss: 1.2527, Disc Loss: 0.6512

...

GAN Epoch 27/30 - Gen Loss: 0.7606, Disc Loss: 1.0664

GAN Epoch 28/30 - Gen Loss: 1.7977, Disc Loss: 1.2931

GAN Epoch 29/30 - Gen Loss: 0.7648, Disc Loss: 1.2459

GAN Epoch 30/30 - Gen Loss: 1.1487, Disc Loss: 0.8000

22.3.2 خرج الشبكة الالتفافية بالنسخة الثالثة – CNN OUTPUT for each Epoch

Epoch 1/30 - loss: 0.0187 - mae: 0.1021 - val_loss: 0.0130 - val_mae: 0.0847
Epoch 2/30 - loss: 0.0169 - mae: 0.0961 - val_loss: 0.0346 - val_mae: 0.1537
Epoch 3/30 - loss: 0.0154 - mae: 0.0923 - val_loss: 0.0144 - val_mae: 0.0876
Epoch 4/30 - loss: 0.0143 - mae: 0.0883 - val_loss: 0.0162 - val_mae: 0.0992
Epoch 5/30 - loss: 0.0136 - mae: 0.0857 - val_loss: 0.0155 - val_mae: 0.0980
Epoch 6/30 - loss: 0.0131 - mae: 0.0840 - val_loss: 0.0144 - val_mae: 0.0876
Epoch 7/30 - loss: 0.0134 - mae: 0.0834 - val_loss: 0.0119 - val_mae: 0.0786

Epoch 8/30 - loss: 0.0122 - mae: 0.0802 - val_loss: 0.0123 - val_mae: 0.0809
Epoch 9/30 - loss: 0.0114 - mae: 0.0769 - val_loss: 0.0102 - val_mae: 0.0757
Epoch 10/30 - loss: 0.0112 - mae: 0.0763 - val_loss: 0.0137 - val_mae: 0.0913
Epoch 11/30 - loss: 0.0117 - mae: 0.0770 - val_loss: 0.0098 - val_mae: 0.0757
Epoch 12/30 - loss: 0.0106 - mae: 0.0734 - val_loss: 0.0108 - val_mae: 0.0806
Epoch 13/30 - loss: 0.0098 - mae: 0.0708 - val_loss: 0.0116 - val_mae: 0.0822
Epoch 14/30 - loss: 0.0094 - mae: 0.0697 - val_loss: 0.0128 - val_mae: 0.0787
Epoch 15/30 - loss: 0.0094 - mae: 0.0692 - val_loss: 0.0116 - val_mae: 0.0819
Epoch 16/30 - loss: 0.0093 - mae: 0.0691 - val_loss: 0.0121 - val_mae: 0.0845
Epoch 17/30 - loss: 0.0087 - mae: 0.0657 - val_loss: 0.0101 - val_mae: 0.0733
Epoch 18/30 - loss: 0.0072 - mae: 0.0602 - val_loss: 0.0099 - val_mae: 0.0732
Epoch 19/30 - loss: 0.0072 - mae: 0.0603 - val_loss: 0.0097 - val_mae: 0.0726
Epoch 20/30 - loss: 0.0071 - mae: 0.0599 - val_loss: 0.0105 - val_mae: 0.0726
Epoch 21/30 - loss: 0.0073 - mae: 0.0600 - val_loss: 0.0096 - val_mae: 0.0717
Epoch 22/30 - loss: 0.0061 - mae: 0.0562 - val_loss: 0.0174 - val_mae: 0.1061
Epoch 23/30 - loss: 0.0060 - mae: 0.0554 - val_loss: 0.0107 - val_mae: 0.0784
Epoch 24/30 - loss: 0.0055 - mae: 0.0526 - val_loss: 0.0096 - val_mae: 0.0725
Epoch 25/30 - loss: 0.0051 - mae: 0.0515 - val_loss: 0.0088 - val_mae: 0.0684
Epoch 26/30 - loss: 0.0051 - mae: 0.0506 - val_loss: 0.0088 - val_mae: 0.0698
Epoch 27/30 - loss: 0.0046 - mae: 0.0491 - val_loss: 0.0094 - val_mae: 0.0707

Epoch 28/30 - loss: 0.0044 - mae: 0.0476 - val_loss: 0.0095 - val_mae: 0.0733
Epoch 29/30 - loss: 0.0043 - mae: 0.0471 - val_loss: 0.0094 - val_mae: 0.0722
Epoch 30/30 - loss: 0.0041 - mae: 0.0461 - val_loss: 0.0087 - val_mae: 0.0697

الخلاصة مع ملاحظات متعلقة بالنسخة الثالثة:

نلاحظ من نتائج التدريب للنسخة التالتة من نموذج الذكاء الصنعي :

- **تذبذب كبير في كل من خسارة المولّد (Gen Loss) والمميّز (Disc Loss) عبر الحِقَب، وهذا أمر شائع في تدريب الـ GAN لأن العمليّة أشبه بـ*لعبة شدّ الحبل* بين المولّد والمميّز . أحيانًا نرى Gen Lossمنخفضة (0.44–0.8) وأحيانًا ترتفع فوق 2.0،**
- **وكذلك Disc Loss تتراوح بين ~0.65 و 2.4**

ملاحظات على هذه النتائج

- **هناك حِقَب يظهر فيها أن المميّز قوي جدًا(Disc Loss > 2) ، وهذا قد يعني أن المولّد يجد صعوبة في خداعه.**
- **وهناك حِقَب أخرى المولّد فيها قوي نسبيًا (Gen Loss منخفضة والمميّز ضعيف(، وهذا قد يؤدي إلى فقدان التوازن إذا استمر.**
- **القيم ليست "سيئة" بالضرورة، لكنها تشير إلى أن التدريب غير مستقر تمامًا — وهو أمر شائع في الـ GAN — وقد يستفيد من تحسينات في الاستقرار.**

- **لا يوجد اتجاه ثابت نحو الانخفاض كما في تدريب الشبكات التقليدية، بل هناك صعود وهبوط مستمر بالتالي ننتقل للنسخة الرابعة والنهائية.**

22.4 النسخة النهائية للتدريب – Final Version:

22.4.1 خرج الشبكة التنافسية بالنسخة الأولى – GAN OUTPUT For Each Epoch

GAN Epoch 1/30 - Gen Loss: 1.0732, Disc Loss: 0.9457
GAN Epoch 2/30 - Gen Loss: 0.6874, Disc Loss: 1.4326
GAN Epoch 3/30 - Gen Loss: 0.7444, Disc Loss: 1.3814
GAN Epoch 4/30 - Gen Loss: 0.6613, Disc Loss: 1.4198
GAN Epoch 5/30 - Gen Loss: 0.7618, Disc Loss: 1.2818
GAN Epoch 6/30 - Gen Loss: 1.0990, Disc Loss: 0.9701
GAN Epoch 7/30 - Gen Loss: 0.8105, Disc Loss: 1.3314
GAN Epoch 8/30 - Gen Loss: 1.2258, Disc Loss: 1.0824

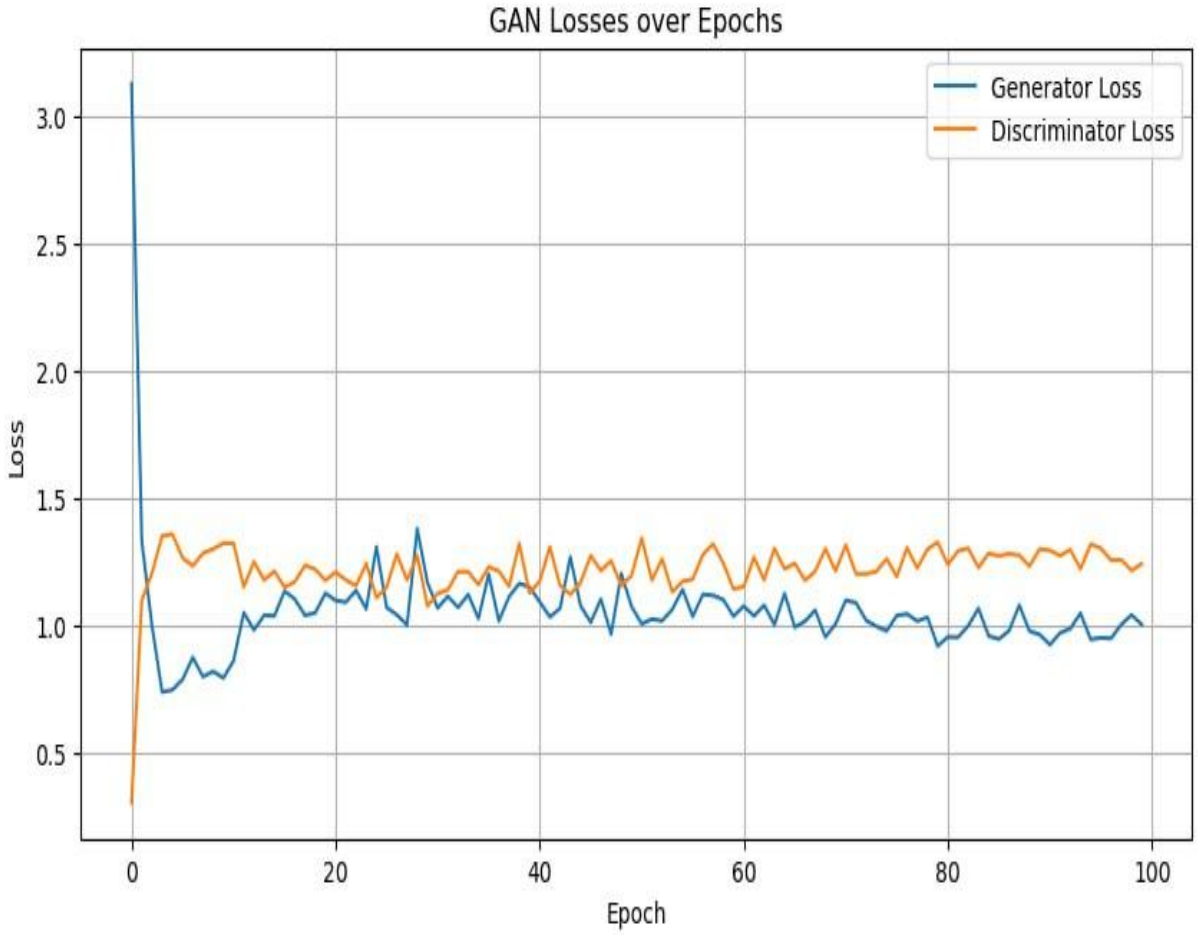
GAN Epoch 9/30 - Gen Loss: 2.1527, Disc Loss: 1.7388
GAN Epoch 10/30 - Gen Loss: 1.0669, Disc Loss: 0.7958
GAN Epoch 11/30 - Gen Loss: 1.1658, Disc Loss: 1.2011
GAN Epoch 12/30 - Gen Loss: 0.8810, Disc Loss: 1.8206
GAN Epoch 13/30 - Gen Loss: 0.7476, Disc Loss: 1.0662
GAN Epoch 14/30 - Gen Loss: 0.8684, Disc Loss: 1.2497
GAN Epoch 15/30 - Gen Loss: 1.0132, Disc Loss: 1.0839
GAN Epoch 16/30 - Gen Loss: 2.0207, Disc Loss: 1.0672
GAN Epoch 17/30 - Gen Loss: 1.0496, Disc Loss: 0.9133
GAN Epoch 18/30 - Gen Loss: 1.1379, Disc Loss: 1.2035
GAN Epoch 19/30 - Gen Loss: 0.8337, Disc Loss: 1.9083
GAN Epoch 20/30 - Gen Loss: 0.5020, Disc Loss: 2.4132
GAN Epoch 21/30 - Gen Loss: 0.6309, Disc Loss: 1.3432
GAN Epoch 22/30 - Gen Loss: 0.4473, Disc Loss: 2.1229
GAN Epoch 23/30 - Gen Loss: 0.6177, Disc Loss: 1.3474
GAN Epoch 24/30 - Gen Loss: 1.1087, Disc Loss: 1.2590
GAN Epoch 25/30 - Gen Loss: 1.2527, Disc Loss: 0.6512
GAN Epoch 26/30 - Gen Loss: 0.9827, Disc Loss: 1.5941
GAN Epoch 27/30 - Gen Loss: 0.7606, Disc Loss: 1.0664
GAN Epoch 28/30 - Gen Loss: 1.7977, Disc Loss: 1.2931
GAN Epoch 29/30 - Gen Loss: 0.7648, Disc Loss: 1.2459
GAN Epoch 30/30 - Gen Loss: 1.1487, Disc Loss: 0.8000

22.4.2 خرج الشبكة الالتفافية بالنسخة الأولى – CNN OUTPUT for each Epoch

Epoch 1/30
loss: 0.0187 - mae: 0.1021 - val_loss: 0.0130 - val_mae: 0.0847
Epoch 2/30
loss: 0.0169 - mae: 0.0961 - val_loss: 0.0346 - val_mae: 0.1537
Epoch 3/30
loss: 0.0154 - mae: 0.0923 - val_loss: 0.0144 - val_mae: 0.0876
Epoch 4/30
loss: 0.0143 - mae: 0.0883 - val_loss: 0.0162 - val_mae: 0.0992
Epoch 5/30
loss: 0.0136 - mae: 0.0857 - val_loss: 0.0155 - val_mae: 0.0980
Epoch 6/30
loss: 0.0131 - mae: 0.0840 - val_loss: 0.0144 - val_mae: 0.0876

Epoch 7/30
loss: 0.0134 - mae: 0.0834 - val_loss: 0.0119 - val_mae: 0.0786
Epoch 8/30
loss: 0.0122 - mae: 0.0802 - val_loss: 0.0123 - val_mae: 0.0809
Epoch 9/30
loss: 0.0114 - mae: 0.0769 - val_loss: 0.0102 - val_mae: 0.0757
Epoch 10/30
loss: 0.0112 - mae: 0.0763 - val_loss: 0.0137 - val_mae: 0.0913
Epoch 11/30
loss: 0.0117 - mae: 0.0770 - val_loss: 0.0098 - val_mae: 0.0757
Epoch 12/30
loss: 0.0106 - mae: 0.0734 - val_loss: 0.0108 - val_mae: 0.0806
Epoch 13/30
loss: 0.0098 - mae: 0.0708 - val_loss: 0.0116 - val_mae: 0.0822
Epoch 14/30
loss: 0.0094 - mae: 0.0697 - val_loss: 0.0128 - val_mae: 0.0787
Epoch 15/30
loss: 0.0094 - mae: 0.0692 - val_loss: 0.0116 - val_mae: 0.0819
Epoch 16/30
loss: 0.0093 - mae: 0.0691 - val_loss: 0.0121 - val_mae: 0.0845
Epoch 17/30
loss: 0.0087 - mae: 0.0657 - val_loss: 0.0101 - val_mae: 0.0733
Epoch 18/30
loss: 0.0072 - mae: 0.0602 - val_loss: 0.0099 - val_mae: 0.0732
Epoch 19/30
loss: 0.0072 - mae: 0.0603 - val_loss: 0.0097 - val_mae: 0.0726
Epoch 20/30
loss: 0.0071 - mae: 0.0599 - val_loss: 0.0105 - val_mae: 0.0726
Epoch 21/30
loss: 0.0073 - mae: 0.0600 - val_loss: 0.0096 - val_mae: 0.0717
Epoch 22/30
loss: 0.0061 - mae: 0.0562 - val_loss: 0.0174 - val_mae: 0.1061
Epoch 23/30
loss: 0.0060 - mae: 0.0554 - val_loss: 0.0107 - val_mae: 0.0784
Epoch 24/30
loss: 0.0055 - mae: 0.0526 - val_loss: 0.0096 - val_mae: 0.0725
Epoch 25/30
loss: 0.0051 - mae: 0.0515 - val_loss: 0.0088 - val_mae: 0.0684
Epoch 26/30
loss: 0.0051 - mae: 0.0506 - val_loss: 0.0088 - val_mae: 0.0698

Epoch 27/30
loss: 0.0046 - mae: 0.0491 - val_loss: 0.0094 - val_mae: 0.0707
Epoch 28/30
loss: 0.0044 - mae: 0.0476 - val_loss: 0.0095 - val_mae: 0.0733
Epoch 29/30
loss: 0.0043 - mae: 0.0471 - val_loss: 0.0094 - val_mae: 0.0722
Epoch 30/30
loss: 0.0041 - mae: 0.0461 - val_loss: 0.0087 - val_mae: 0.0697



الشكل: 20 - 1يوضح تدرب الشبكة وعدم انهيار النموذج



الشكل: 20 - 2 يوضح الشكل تدرب شبكة ال CNN

22.4.3 ملخّص التدريب والتقييم

- **المقاييس:**
  - **loss:** مقياس الخطأ على بيانات التدريب (كلما كان أقل كان أفضل).
  - **mae:** متوسط الخطأ المطلق على بيانات التدريب (كلما كان أقل كان أفضل).
  - **val_loss:** مقياس الخطأ على بيانات التحقق (البيانات غير المستخدمة في التدريب).
  - **val_mae:** متوسط الخطأ المطلق على بيانات التحقق.

- **الملاحظات من النتائج:**

القيم **تنخفض تدريجياً** عبر الحقب (epochs) في كل من التدريب والتحقق، وهذا مؤشر على أن النموذج يتعلم بشكل جيد.

الفارق بين التدريب والتحقق **صغير**، مما يعني أن النموذج لا يعاني من فرط التعلّم.(Overfitting)

في النهاية، وصلت قيمة **val_mae** إلى حوالي **0.07**، أي أن متوسط الخطأ في التنبؤات على البيانات الجديدة يقارب 7% من المجال الكلي للقيم (أو 0.07 وحدة إذا كانت القيم مُطبّعة بين 0 و1).

- **التقييم:**
  - النموذج أظهر تحسنًا ثابتًا في الأداء مع مرور الحقب.
  - التذبذبات في منحنى التحقق طبيعية، لكنها تستحق المراقبة في حال زيادة الفارق بين التدريب والتحقق.
  - يمكن اعتبار الحقبة 25 نقطة الأداء المثالي، حيث توازن بين أقل خطأ وأعلى دقة على بيانات التحقق

- الرسم البياني يعكس عملية تدريب ناجحة لشبكة GAN حيث توازن كل من المولد والمميز بعد فترة قصيرة من التدريب، مع بقاء الخسائر في نطاق مستقر (≈1)، مما يشير إلى أن النموذج يتعلم بطريقة تنافسية فعّالة دون انهيار (Mode Collapse) أو هيمنة طرف على الآخر.



- **نلاحظ وضوح ملامح الوجه الأساسية (العينان، الأنف، الفم) مع إضاءة متجانسة وغياب تشويش لوني أو خطوط، كون الصورة رمادية عالية التباين.**



- **الملامح واضحة جدًا، مع توزيع إضاءة متوازن وغياب تشويش، مما يوفر للنموذج مدخلات نظيفة.**

22.4.4 خلاصة ومقارنة للنتائج بالنسخ السابقة

النسخة الأولى

- **الطابع العام :**صور بملامح أوضح نسبيًا رغم التشويش اللوني والخطي.
- **الأخطاء :**معظم الانحرافات في التقدير كانت صغيرة إلى متوسطة (±2–4 سنوات)، باستثناء حالة واحدة بانحراف أكبر.
- **نوع التشويش :**خطوط أفقية ملوّنة (RGB) تؤثر على التفاصيل الدقيقة، لكن شكل الوجه العام محفوظ.
- **أداء النموذج :**يميل إلى الاقتراب من العمر الحقيقي في أغلب الحالات، مع بعض الانحرافات السالبة أو الموجبة الطفيفة.

النسخة الثانية

- **الطابع العام :**صور بتمثيل شبكي أو نقطي حراري (أحمر/أصفر/أخضر)، أحيانًا مع خطوط أفقية، ما يقلل وضوح الملامح الدقيقة.
- **الأخطاء :**تفاوت أكبر في الانحراف، من قريب جدًا للعمر الحقيقي إلى انحراف كبير (حوالي - 3 سنوات).
- **نوع التشويش :**مزيج من تمثيل حراري شبكي وتشويش أفقي، مع فقدان أكبر للتفاصيل الدقيقة حول العينين والفم.

- **أداء النموذج :**أكثر حساسية للتشويش، وأحيانًا يخطئ بشكل ملحوظ في الأعمار الأصغر.

النسخة الثالثة:

- **القيم ليست "سيئة" بالضرورة، لكنها تشير إلى أن التدريب غير مستقر تمامًا — وهو أمر شائع في الـ GAN — وقد يستفيد من تحسينات في الاستقرار.**

- **لا يوجد اتجاه ثابت نحو الانخفاض كما في تدريب الشبكات التقليدية، بل هناك صعود وهبوط مستمر.**

النسخة النهائية :

- **وضوح الملامح :كلتا الصورتين تتمتعان بوضوح عالٍ وإضاءة جيدة، ما يعني أن الخطأ ليس بسبب جودة الصورة.**
- **حجم الانحراف :الانحراف أكبر في الصورة الأولى (+6.9) مقارنة بالثانية (+3.5)، ما يشير إلى أن النموذج أكثر عرضة للمبالغة في تقدير الأعمار الكبيرة نسبيًا.**
- **أظهر النموذج كفاءة عالية في استخلاص السمات العمرية من الصور الرمادية، مع قدرة واضحة على التعميم عبر فئات عمرية مختلفة. كما تميز بثبات نسبي في الأداء ودقة تقدير متقاربة من القيم الحقيقية، مما يعكس جودة المعايرة وقابلية التطوير نحو مستويات أعلى من الدقة.**

23 الخلاصة:

الشبكات التوليدية الخصمية (GANs) تمثل نقلة نوعية في الذكاء الاصطناعي؛ إذ جمعت بين قوة التعلّم التمثيلي (Representation Learning) والقدرة على التوليد .(Generation) على الرغم من صعوبات التدريب ومشاكل الاستقرار، إلا أن إنجازاتها في مجالات الفن، الواقع الافتراضي، تحسين البيانات، والأمن تجعلها **واحدة من أهم وأقوى البنى العصبية في عصرنا الحالي.**

إن فكرة التنافس بين المولّد والمميّز ليس مجرد خوارزمية رياضية، بل هو استعارة لعبقرية الفكرة **:من خلال الصراع يتحقق الإبداع.**

لمشاكل الصورة أيضا، فإن تغذية الصور مباشرة في الشبكات العصبية التغذية الأمامية سيكون مكلفا من الناحية الحسابية.

24 الخاتمة

تصنيف العمر من الصور ليس مجرد مهمة تصنيف عادية، بل هو تحدي حقيقي في فهم وتعليم الآلة للتمييز بين التفاصيل الدقيقة والسمات المميزة للوجوه البشرية. يتطلب نجاح هذا المشروع دمجاً بين تقنيات الذكاء الاصطناعي الحديثة، ومعرفة دقيقة بالتفاصيل البشرية، والتعامل مع تحديات البيانات الحقيقية المعقدة.

المشروع لا يُعد فقط تدريباً أكاديمياً على بناء الشبكات العصبية، بل هو فرصة لاستكشاف كيفية تقاطع **العلوم الإنسانية (Human Perception)** مع تقنيات الذكاء الاصطناعي في بناء نماذج قادرة على قراءة الإنسان وفهمه بصرياً.

25 آفاق البحث والتطوير:(Future Work and Improvements)

دمج تقنيات **Attention Mechanisms**لجعل النموذج يركّز على المناطق الهامة في الوجه (مثل العيون، التجاعيد).

استخدام **Ordinal Regression Techniques**للتعامل مع ترتيب العمر.

استكشاف **Face Landmark Detection**لتحسين الدقة في الصور ذات الزوايا الصعبة.

تدريب النماذج باستخدام مجموعات بيانات ميدانية (Real-World Datasets) لزيادة التفاعل مع بيئات واقعية.

المراجع

1. Artificial Intelligence: A Modern Approach – Stuart Russell & Peter Norvig

2. Deep Learning – Ian Goodfellow, Yoshua Bengio, Aaron Courville

3. Computer Vision: Algorithms and Applications – Richard Szeliski

4. Pattern Recognition and Machine Learning – Christopher Bishop

5. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow – Aurélien Géron

Abstract

Abstract This study explores the integration of Generative Adversarial Networks (GANs) and Convolutional Neural Networks (CNNs) to improve age estimation from facial images in scenarios with limited training data. A GAN model was trained to synthesize realistic facial images, thereby augmenting the original dataset and increasing its diversity.
The augmented dataset was subsequently used to train a CNN for age prediction, with the aim of enhancing model generalization and reducing overfitting. Experimental results indicate that the inclusion of GAN-generated samples led to a measurable improvement in prediction accuracy, achieving **more** accuracy when trained solely on the original dataset.
These findings demonstrate the effectiveness of GAN-based data augmentation in boosting CNN performance for age estimation tasks, and highlight its potential applicability to other computer vision problems constrained by limited data availability.